

Automatización inteligente del flujo de pedidos para un mercado de frutas y verduras

Esp. Ing. Joaquín Manuel Beitia

Maestría en Computación de Borde

Director: Matías Martini (Xepelin)

Jurados:

Jurado 1 (pertenencia)

Jurado 2 (pertenencia)

Jurado 3 (pertenencia)

Ciudad de Rosario, julio de 2026

Resumen

El presente trabajo consiste en el diseño e implementación de un sistema que automatiza la recepción, interpretación y el procesamiento de los pedidos de un mercado de frutas y verduras recibidos a través de mensajería instantánea. El sistema captura pedidos en texto, voz, imagen o documento, e identifica productos, cantidades y unidades mediante modelos de inteligencia artificial. Una vez estructurado el pedido, se imprime en el comercio mediante una impresora térmica conectada a un servidor local. El desarrollo fue realizado para la Tienda de frutas Luján, con el fin de reducir los tiempos operativos, disminuir los errores humanos y mejorar la trazabilidad de la gestión comercial.

Para su desarrollo se aplicaron conocimientos propios de la computación de borde, tales como la distribución del procesamiento entre el borde y la nube, la comunicación segura entre nodos, la actuación local sobre hardware y el diseño de soluciones de bajo costo.

Agradecimientos

Quiero expresar mi agradecimiento a la Tienda de frutas Luján, y en particular a Marcos y Cristian Cestari, por la confianza depositada en este trabajo y por abrir las puertas de su comercio para el desarrollo y la validación del sistema. Su predisposición y su conocimiento del negocio fueron fundamentales para orientar el trabajo hacia una solución realmente útil.

Agradezco también a mi director, Matías Martini, cuya orientación y experiencia en desarrollo de software e inteligencia artificial aplicada guiaron las decisiones técnicas a lo largo del desarrollo.

Mi reconocimiento se extiende a mis compañeros y colegas, cuya colaboración fue esencial para superar los desafíos surgidos durante la implementación. Por último, agradezco a mis amigos y a mi familia, cuya paciencia y aliento incondicional fueron mi sostén durante este proceso, permitiéndome perseguir mis proyectos y crecer profesionalmente.

Índice general

Resumen	I
1. Introducción general	1
1.1. Mensajería instantánea y gestión de pedidos en comercios minoristas	1
1.2. Contexto y motivación	2
1.3. Estado del arte	3
1.3.1. Soluciones basadas en la nube	3
1.3.2. Plataformas de automatización de mensajería	3
1.3.3. Enfoques de borde e híbridos	4
1.3.4. Comparación y posicionamiento del trabajo	4
1.4. Objetivos del trabajo	4
2. Introducción específica	7
2.1. Dispositivos de borde	7
2.1.1. Servidor local	7
2.1.2. Impresora térmica	8
2.2. Protocolos de comunicación	8
2.2.1. Canal de mensajería	8
2.2.2. Comunicación segura con la nube	9
2.3. Plataformas cloud y servicios	9
2.3.1. Orquestación de flujos de trabajo	9
2.3.2. Infraestructura de despliegue	10
2.3.3. Servicios de inteligencia artificial	10
2.4. Herramientas de almacenamiento y visualización	11
2.4.1. Bases de datos	11
2.4.2. Servidor local y panel de visualización	11
3. Diseño e implementación	13
3.1. Arquitectura del sistema	13
3.1.1. Criterio de distribución del cómputo	14
3.1.2. Organización del código	14
3.1.3. Entorno de desarrollo	14
3.1.4. Flujo de datos extremo a extremo	15
3.2. Capa de captura y comunicación	15
3.2.1. Recepción de los mensajes	15
3.2.2. Clasificación y procesamiento por tipo de contenido	16
3.2.3. Agrupación de mensajes fragmentados	17
3.3. Capa de red y comunicaciones	17
3.3.1. Tramos de comunicación	17
3.3.2. Vinculación con el nodo de borde	18
3.3.3. Formato de los mensajes intercambiados	18
3.4. Capa de aplicación y procesamiento	20

3.4.1.	Interpretación mediante agentes de inteligencia artificial . .	20
3.4.2.	Normalización semántica de productos	21
3.4.3.	Recursos de la interfaz de programación	21
3.4.4.	Modelo de datos	21
3.4.5.	Resolución de precios	22
3.4.6.	Generación del ticket	23
3.5.	Interfaz de usuario y visualización	23
3.5.1.	El ticket impreso	23
3.5.2.	El panel web de control	24
3.6.	Seguridad del sistema	26
3.6.1.	Autenticación y control de acceso	26
3.6.2.	Protección de las comunicaciones	27
3.6.3.	Gestión de credenciales e integridad de los datos	27
4.	Ensayos y resultados	29
4.1.	Plan de ensayos	29
4.1.1.	Alcance y ventanas de medición	29
4.1.2.	Instrumentos de medición	30
4.1.3.	Estrategia de verificación adoptada	31
4.1.4.	Criterios de evaluación	31
4.2.	Ensayos de conectividad y comunicación	31
4.2.1.	Confiabilidad del vínculo en operación	32
4.2.2.	Análisis de los episodios de pérdida de conectividad	32
4.3.	Ensayos de la capa de aplicación	33
4.3.1.	Tasa de reconocimiento de ítems	33
4.3.2.	Análisis de los ítems no reconocidos	34
4.3.3.	Estabilidad de la orquestación	35
4.4.	Ensayos de integración extremo a extremo	36
4.4.1.	Latencia de la actuación en el borde	36
4.4.2.	Composición de la latencia extremo a extremo	37
4.4.3.	Auditoría por formato de entrada	39
4.4.4.	Trazabilidad del pedido	41
4.5.	Análisis de resultados	42
4.5.1.	Verificación de los requerimientos	42
4.5.2.	Limitaciones detectadas	42
4.5.3.	Mejoras propuestas	43
5.	Conclusiones	45
5.1.	Conclusiones generales	45
5.1.1.	Grado de cumplimiento de los objetivos	45
5.1.2.	Fidelidad respecto de la planificación	46
5.1.3.	Comportamiento de los riesgos identificados	47
5.1.4.	Técnicas empleadas	48
5.2.	Próximos pasos	48
A.	Capturas del sistema en operación	51
A.1.	Ticket impreso	53
A.2.	Panel web de control	54
	Bibliografía	59

Índice de figuras

1.1. Esquema conceptual del sistema: capas, componentes y flujo de datos.	2
3.1. Arquitectura del sistema en tres capas.	13
3.2. Procesamiento de la capa de captura, desde el mensaje entrante hasta el texto agrupado.	16
3.3. Topología de despliegue del sistema.	18
3.4. Diagrama entidad-relación de la base de datos.	22
3.5. Esquema de los campos que componen el ticket.	24
3.6. Estructura de navegación del panel web de control.	25
3.7. Mecanismos de autenticación para personas y para servicios internos.	26
4.1. Distribución del tiempo transcurrido entre la persistencia del pedido y su primera impresión.	37
4.2. Distribución de la duración de las ejecuciones del flujo de interpretación de pedidos.	38
A.1. Ticket real generado por el sistema e impreso en el comercio.	53
A.2. Tablero principal del panel de control.	54
A.3. Listado de pedidos con sus filtros de búsqueda.	55
A.4. Detalle de un pedido, con edición de ítems y acceso al mensaje original.	56
A.5. Administración del catálogo de productos.	56
A.6. Administración de las listas de precios de un cliente.	57
A.7. Vista de métricas de operación del comercio.	57

Índice de tablas

1.1. Comparación de paradigmas para la automatización de pedidos en el comercio minorista.	4
3.1. Grupos de recursos de la interfaz de programación.	21
4.1. Ventanas de medición empleadas en los ensayos.	30
4.2. Clasificación de los errores registrados durante la operación automática.	32
4.3. Episodios de pérdida de conectividad registrados durante la operación automática.	33
4.4. Clasificación de los ítems no asociados al catálogo.	34
4.5. Ejecuciones registradas por flujo de orquestación.	36
4.6. Latencia de la impresión automática en el nodo de borde.	37
4.7. Auditoría por formato de entrada sobre los pedidos atribuidos. . .	40
4.8. Verificación de los requerimientos a partir de los ensayos realizados.	42

A mi familia.

Capítulo 1

Introducción general

En el presente capítulo se introduce el área en la que se enmarca el trabajo, se describe el contexto y la motivación que dieron origen al desarrollo, se revisan las soluciones existentes para problemas similares y se enuncian los objetivos perseguidos.

1.1. Mensajería instantánea y gestión de pedidos en comercios minoristas


La creciente adopción de canales de mensajería instantánea como medio de contacto comercial modificó la forma en que los pequeños y medianos comercios reciben los pedidos de sus clientes. En el rubro de los mercados de frutas y verduras, gran parte de las ventas se gestiona a través de aplicaciones de mensajería, donde los pedidos llegan en formatos heterogéneos: texto libre, mensajes de voz, fotografías de listas manuscritas o capturas de pantalla. La interpretación de estos mensajes y su conversión en un pedido preparable constituyen, hoy, una tarea manual realizada por el personal del comercio.

El trabajo se sitúa en la intersección entre la automatización de procesos comerciales y la computación de borde (*edge computing*), entendida esta última como el paradigma en el que parte del procesamiento y la toma de decisiones se ejecutan cerca del lugar donde se generan y se consumen los datos, en lugar de delegarse íntegramente a la nube. En un comercio minorista, el “borde” es el propio local: allí se recibe el pedido, allí debe imprimirse el ticket para su armado y allí ocurre la operación que no puede detenerse ante una caída de conectividad. Este enfoque contrasta con las arquitecturas puramente basadas en la nube, en las que todo el procesamiento se centraliza en servidores remotos.

El sistema desarrollado combina componentes de inteligencia artificial (IA) para la interpretación de los mensajes con una infraestructura de Internet de las cosas (IoT, del inglés *Internet of Things*) para la actuación física en el local, articulados mediante una arquitectura híbrida que distribuye el cómputo entre un servidor local en el comercio y servicios alojados en la nube. El foco de esta memoria está puesto en los aspectos propios de la computación de borde: la distribución del procesamiento entre el borde y la nube, la comunicación segura entre ambos, la actuación local sobre hardware y las restricciones de costo, latencia y disponibilidad características de estos entornos. Los fundamentos de aprendizaje de máquina y aprendizaje profundo se asumen conocidos y no se desarrollan en detalle.

En la figura 1.1 se presenta un esquema conceptual de alto nivel del sistema, en el que el pedido ingresa por el canal de mensajería, se interpreta en la nube y

deriva en la impresión local del ticket y en la visualización de la operación. La arquitectura detallada del sistema se describe en el capítulo 3.



Trazo continuo: componentes del sistema.

Trazo punteado: datos que circulan entre los componentes.

FIGURA 1.1. Esquema conceptual del sistema: capas, componentes y flujo de datos.

1.2. Contexto y motivación

El trabajo se desarrolló para la Tienda de frutas Luján, un comercio minorista de frutas y verduras que recibe sus pedidos principalmente a través de mensajería instantánea. En la operación actual, un integrante del negocio lee cada mensaje entrante, interpreta su contenido (que puede llegar como texto, audio o imagen), normaliza los nombres y las cantidades de los productos y transcribe el pedido a un formato que permita su preparación y despacho.

Este proceso manual presenta varias limitaciones. En primer lugar, consume tiempo del personal que podría destinarse a la atención y a la preparación de los pedidos, y su capacidad se satura en los horarios de mayor demanda. En segundo

lugar, la transcripción manual es propensa a errores de interpretación, especialmente ante mensajes de voz extensos, listas manuscritas poco legibles o denominaciones ambiguas de un mismo producto. En tercer lugar, al no existir un registro estructurado de los pedidos, se pierde trazabilidad: resulta difícil reconstruir el historial de un cliente, auditar un pedido puntual o extraer información agregada para la gestión comercial.

La motivación del desarrollo es, entonces, doble. Por un lado, se busca reducir los tiempos operativos y los errores humanos mediante la automatización de la recepción, interpretación e impresión de los pedidos. Por el otro, se procura hacerlo con una solución accesible y de bajo costo, adecuada a la realidad de un comercio que no dispone de infraestructura tecnológica avanzada ni de personal técnico especializado. Esta última condición es la que justifica el enfoque de computación de borde: procesar y actuar localmente permite que la operación crítica (la impresión del ticket para armar el pedido) funcione con baja latencia y sin depender por completo de la disponibilidad de servicios remotos.

1.3. Estado del arte

La automatización de la recepción de pedidos en el comercio minorista puede abordarse desde distintos paradigmas, que se diferencian principalmente por dónde se ejecuta el procesamiento y por el grado de adaptación al canal de mensajería informal. A continuación, se revisan las alternativas existentes y se las contrasta con el enfoque adoptado en este trabajo.

1.3.1. Soluciones basadas en la nube

Una parte importante de las soluciones comerciales de gestión de pedidos y punto de venta se ofrece bajo el modelo de software como servicio, con todo el procesamiento centralizado en la nube. Entre las plataformas más conocidas se encuentran Shopify [1] y, en el mercado local, Tiendanube [2], que ofrecen soluciones de punto de venta y gestión de pedidos. Estas plataformas ofrecen paneles de administración, reportes y, en algunos casos, integración con canales de mensajería. Su principal ventaja es que no requieren infraestructura local más allá de un dispositivo con conexión a Internet. Sus limitaciones, en el contexto de este trabajo, son la dependencia total de la conectividad para operar, los costos recurrentes de suscripción y la escasa capacidad de personalización frente a un flujo de pedidos informal y no estructurado como el que se recibe por mensajería.

1.3.2. Plataformas de automatización de mensajería

Existen plataformas y herramientas de automatización de flujos de trabajo que permiten conectar canales de mensajería con otros servicios mediante reglas o disparadores, como n8n [3] o Zapier [4]. Estas soluciones habilitan respuestas automáticas y la orquestación de tareas, pero por sí solas no resuelven la interpretación semántica de un pedido expresado en lenguaje natural, en audio o en una imagen. Para ello deben combinarse con modelos de procesamiento de lenguaje, reconocimiento de voz y reconocimiento óptico de caracteres (OCR, del inglés *Optical Character Recognition*).

1.3.3. Enfoques de borde e híbridos

Frente a los esquemas puramente centralizados, la computación de borde propone ejecutar parte del procesamiento cerca del origen de los datos [5, 6]. En el comercio minorista, este enfoque resulta atractivo cuando existe una actuación física local, como la impresión de un ticket, que debe ocurrir con baja latencia y tolerancia a fallos de conectividad. Las arquitecturas híbridas, que combinan un nodo local con servicios en la nube, permiten equilibrar la capacidad de cómputo de la nube con la inmediatez y la resiliencia del procesamiento local [7].

1.3.4. Comparación y posicionamiento del trabajo

En la tabla 1.1 se comparan los tres paradigmas descriptos según los criterios más relevantes para el caso de uso abordado. El trabajo desarrollado se posiciona en el enfoque híbrido. En la nube se ejecutan las tareas de mayor demanda de cómputo, como la interpretación de los mensajes mediante modelos de IA. En el borde se ejecuta la actuación crítica y de baja latencia, es decir, la impresión local del pedido. De este modo, se busca un compromiso entre costo, personalización y disponibilidad, adecuado a un comercio de baja complejidad tecnológica.

TABLA 1.1. Comparación de paradigmas para la automatización de pedidos en el comercio minorista.

Criterio		Nube pura	Automatización de mensajería	Enfoque híbrido (este trabajo)
Procesamiento local	No	No	Parcial	Sí (actuación local)
Dependencia de conectividad	Alta	Alta	Alta	Media
Personalización del flujo	Baja	Media	Media	Alta
Costo de infraestructura	Bajo	Bajo	Bajo	Bajo/Medio
Trazabilidad estructurada	Variable	Baja	Baja	Alta

1.4. Objetivos del trabajo

El objetivo general del trabajo fue diseñar e implementar un sistema de automatización de pedidos. El sistema abarca la recepción, la interpretación y el procesamiento de los pedidos de un mercado de frutas y verduras recibidos a través de mensajería. De este modo se buscó reducir los tiempos operativos, minimizar los errores humanos y mejorar la trazabilidad de la operación comercial.

Para alcanzarlo, se definieron los siguientes objetivos específicos, formulados de manera concreta y verificable:

- Capturar de forma automática los pedidos entrantes por el canal de mensajería, en sus distintos formatos: texto, voz, imagen y documento.

- Interpretar el contenido de cada pedido mediante modelos de inteligencia artificial, para identificar productos, cantidades y unidades, y normalizar denominaciones equivalentes de un mismo producto.
- Generar, a partir de esa interpretación, un pedido en formato estructurado y persistirlo de manera que quede registrada la trazabilidad completa, desde la recepción hasta la impresión.
- Imprimir automáticamente el pedido en una impresora térmica conectada a un servidor local, para garantizar la actuación en el borde con baja latencia.
- Establecer una comunicación segura entre el servidor local y los servicios en la nube.
- Proveer un panel web que permita visualizar los pedidos en tiempo real, el historial y métricas básicas de operación.
- Validar el sistema en condiciones reales de operación en el comercio.

El alcance del trabajo se limita al flujo de recepción, interpretación, impresión y visualización de pedidos. Las tecnologías y componentes de terceros empleados en la construcción del sistema se describen en el capítulo [2](#), mientras que el diseño y la implementación de la arquitectura se detallan en el capítulo [3](#).

Capítulo 2

Introducción específica

En este capítulo se describen los dispositivos de borde, los protocolos de comunicación, las plataformas en la nube, los servicios de inteligencia artificial y las herramientas de almacenamiento y visualización que constituyen la base tecnológica del sistema.

2.1. Dispositivos de borde

El nodo de borde del sistema está constituido por un servidor local instalado en el comercio y por una impresora térmica conectada a él. A diferencia de un sistema de Internet de las Cosas tradicional, no se emplean microcontroladores ni sensores. El dispositivo de borde es un equipo de cómputo de propósito general que ejecuta los servicios locales y comanda la impresión de los pedidos.

2.1.1. Servidor local

Como servidor local se utiliza una computadora con sistema operativo Windows Server 2019 [8], propiedad del cliente y preexistente en el local. Sobre este equipo se ejecutan el servidor de impresión y el cliente del túnel seguro hacia la nube.

Se evaluaron dos alternativas para el nodo de borde. La primera consistió en incorporar una computadora de placa única (SBC, del inglés *Single Board Computer*) dedicada, como una Raspberry Pi [9]. La segunda consistió en reutilizar el equipo ya disponible en el comercio. Se optó por la segunda opción por tres motivos. El primero fue el costo, dado que reutilizar el hardware disponible elimina la inversión marginal en equipamiento. El segundo fue la operación, ya que el equipo permanece encendido durante el horario comercial y resulta conocido por el personal, lo que simplifica la instalación y el mantenimiento. El tercero fue la compatibilidad, porque la impresora provee controladores para Windows y su integración no requirió desarrollos de bajo nivel.

Como contrapartida, un equipo de propósito general consume más energía que una SBC dedicada y puede verse condicionado por otros usos dentro del comercio. Esta limitación se consideró aceptable frente a la simplicidad operativa obtenida.

También se descartó el uso de un microcontrolador, ya que el conjunto de responsabilidades del nodo de borde (un servidor web local, el cliente del túnel seguro y la administración de la cola de impresión) se resuelve de manera más conveniente sobre un sistema operativo completo.

2.1.2. Impresora térmica

Para la impresión de los tickets se utiliza una impresora térmica Hasar P-HAS-181 [10], un modelo de tipo comandera del fabricante argentino Grupo Hasar, orientado al punto de venta. La impresora imprime por cabezal térmico directo sobre rollos de papel de 80 mm de ancho y dispone de tres interfaces de conexión (puerto serie, USB y Ethernet) y de controladores para Windows. Sus comandos de impresión resultan compatibles con ESC/POS [11], el conjunto de instrucciones definido por Epson que constituye el estándar de facto del sector.

En la instalación actual, la impresora se conecta al servidor local por USB. La disponibilidad de una interfaz Ethernet fue, sin embargo, un criterio de selección. El equipo puede requerir un cambio de ubicación dentro del comercio, por ejemplo hacia el sector de armado de pedidos. La conexión por red permitiría ese traslado sin dependencia de la proximidad física con el servidor.

La elección de este modelo se fundamentó en cuatro factores. La impresión térmica es el estándar del comercio minorista por su velocidad y su bajo costo operativo, al no utilizar tinta ni cartuchos. La compatibilidad con ESC/POS permite comandar el equipo desde bibliotecas ampliamente disponibles, sin depender de un protocolo propietario. Los controladores para Windows garantizan la integración directa con el servidor local. Por último, se trata de un fabricante nacional, lo que asegura la provisión local de insumos, repuestos y servicio técnico, un criterio relevante para un comercio sin personal técnico propio.

2.2. Protocolos de comunicación

El intercambio de mensajes entre los componentes se realiza mediante HTTP [12], con interfaces que siguen el estilo arquitectónico REST [13]. La elección responde a que todos los servicios involucrados exponen sus funcionalidades a través de interfaces de programación de aplicaciones (API, del inglés *Application Programming Interface*) basadas en HTTP. Para los eventos asincrónicos, como la llegada de un mensaje, se emplean notificaciones automáticas (*webhooks*), que evitan que el sistema receptor deba consultar de forma periódica por novedades.

2.2.1. Canal de mensajería

La vinculación con WhatsApp [14] se realiza mediante Evolution API [15], una pasarela de mensajería de código abierto que expone las funciones de la plataforma a través de una interfaz REST y de notificaciones automáticas. Evolution API admite dos modos de conexión: uno basado en el protocolo de WhatsApp Web mediante la biblioteca Baileys [16], sin verificación comercial ante Meta, y otro basado en la API oficial WhatsApp Business Cloud [17]; este trabajo utiliza el primero. Ante cada mensaje entrante, de texto, voz o imagen, la pasarela emite una notificación con el contenido o con las referencias para descargarlo. Junto a Evolution API opera Chatwoot [18], una plataforma de gestión de conversaciones que centraliza la bandeja de entrada de WhatsApp y permite al personal consultar el hilo original de cada conversación.

La elección de Evolution API respondió a su costo nulo, su rapidez de puesta en marcha (sin verificación comercial ni aprobación de plantillas) y su despliegue autoalojado, coherente con la infraestructura del sistema. Su limitación es que

el modo WhatsApp Web es un mecanismo no oficial, con riesgo de restricciones de estabilidad y cumplimiento; por eso el sistema se diseñó compatible con la API oficial de WhatsApp Business, sin que la migración prevista exija cambios estructurales en los flujos de procesamiento.

2.2.2. Comunicación segura con la nube

Para vincular los servicios en la nube con el servidor local sin apertura de puertos en la red del comercio, se emplea un túnel seguro provisto por Cloudflare [19]. Un cliente ligero, ejecutado en el servidor local, establece una conexión cifrada saliente hacia la infraestructura del proveedor. A través de esa conexión, los servicios remotos alcanzan al nodo de borde.

Se consideraron dos alternativas. La apertura de puertos en el enrutador del local exige configurar el equipamiento de red y deja un servicio a la escucha de conexiones entrantes desde Internet, lo que amplía la superficie de ataque. Una red privada virtual (VPN, del inglés *Virtual Private Network*) resuelve la seguridad, pero agrega administración de claves y configuración en ambos extremos. El túnel de Cloudflare, en cambio, no requiere configuración del enrutador, ya que la conexión es saliente, cifra el tráfico de extremo a extremo y mantiene la red interna sin exposición entrante, con una operación mínima acorde a un local sin personal técnico.

2.3. Plataformas cloud y servicios

En esta sección se describen los servicios en la nube sobre los que se apoya el sistema, que comprenden la plataforma de orquestación de los flujos de procesamiento, la infraestructura donde se despliegan los componentes y los servicios de inteligencia artificial que resuelven la interpretación de los pedidos.

2.3.1. Orquestación de flujos de trabajo

La orquestación de las tareas de recepción, interpretación y estructuración de los pedidos se realiza con n8n [3], una plataforma de automatización de flujos de trabajo de código abierto. En n8n, la lógica se construye mediante la conexión de nodos configurables (disparadores, transformaciones e integraciones con servicios externos) en flujos visuales. Este enfoque permite integrar servicios heterogéneos sin desarrollar desde cero la lógica de integración. La plataforma incorpora además agentes de inteligencia artificial (*AI Agents*), que encadenan modelos de lenguaje con herramientas y fuentes de datos. Sobre esa capacidad se apoya la interpretación de los pedidos.

Frente a alternativas comerciales de automatización en la nube, como Zapier [4], n8n presentó dos ventajas decisivas para este trabajo. La primera es la posibilidad de autoalojamiento en la propia infraestructura, sin costo por tarea ejecutada, un factor crítico dado el volumen diario de mensajes. La segunda es que los datos de los clientes permanecen dentro del entorno controlado por el sistema, sin atravesar una plataforma de terceros adicional.

2.3.2. Infraestructura de despliegue

Los servicios en la nube se alojan en un servidor privado virtual (VPS, del inglés *Virtual Private Server*) del proveedor Hostinger [20], en su plan KVM 4. Este plan provee 4 núcleos virtuales, 16 GB de memoria RAM, 200 GB de almacenamiento NVMe y 16 TB de transferencia mensual. El dimensionamiento respondió a la carga concurrente del sistema, ya que sobre el mismo servidor conviven la pasarela de mensajería, el motor de flujos, las bases de datos y el panel web.

Todos los servicios se despliegan de forma contenerizada mediante Docker [21]. La contenerización empaqueta cada servicio junto con sus dependencias en unidades aisladas y reproducibles, lo que permite describir el despliegue en archivos versionables, reproducir el entorno sin diferencias de configuración y actualizar cada componente de manera independiente.

2.3.3. Servicios de inteligencia artificial

La interpretación de los pedidos requiere resolver tres tareas diferenciadas: convertir los mensajes de voz en texto, leer las listas manuscritas enviadas como fotografía y extraer de un texto informal los productos, las cantidades y las unidades solicitadas. Cada tarea se resuelve con un modelo de inteligencia artificial consumido como servicio en la nube, provisto por OpenAI [22] o por Anthropic [23].

La transcripción de audio se realiza con el servicio de transcripción de OpenAI, basado en el modelo Whisper [24], elegido por su robustez frente a condiciones adversas de grabación (ruido de fondo, variabilidad de acentos, calidad desigual del micrófono), determinante porque los mensajes de voz se graban dentro del comercio o en la vía pública, sin control sobre el entorno sonoro.

La lectura de las imágenes se resuelve con modelos multimodales de visión, en lugar de un motor de reconocimiento óptico de caracteres (OCR, del inglés *Optical Character Recognition*) clásico, que pierde precisión ante las imágenes recibidas (listas manuscritas con caligrafías dispares e iluminación irregular, y capturas de planillas) por operar sobre cada carácter de manera aislada, sin considerar la disposición del contenido. Los modelos multimodales, en cambio, interpretan la imagen en su contexto, reconocen la estructura tabular y aprovechan el conocimiento del dominio para resolver ambigüedades.

Sobre cada imagen se ejecutan dos modelos de proveedores distintos, GPT-4o de OpenAI y Claude Sonnet de Anthropic, porque ante una misma imagen producen en ocasiones lecturas discrepantes, sobre todo con caligrafías difíciles o planillas complejas; las dos se reconcilian en un tercer paso, donde GPT-5.5 de OpenAI las compara, corrige las diferencias y devuelve una transcripción única.

La estructuración final se resuelve con un modelo extenso de lenguaje (LLM, del inglés *Large Language Model*), GPT-5.5 de OpenAI, integrado como agente dentro del flujo, que recibe el texto del pedido junto con el catálogo del comercio y produce una representación estructurada con los productos, las cantidades y las unidades. Su capacidad de interpretar lenguaje informal, con abreviaturas, errores de tipeo y denominaciones no normalizadas, constituye el aporte central de estos modelos a la solución.

Consumir estos modelos como servicio, en lugar de ejecutarlos sobre la propia infraestructura, define la distribución del cómputo entre el borde y la nube: los tres

exigen recursos muy superiores a los del nodo de borde, por lo que su ejecución local no resultaba viable con el equipamiento del comercio, y su consumo como servicio mantiene mínima la inversión inicial y la complejidad operativa. El costo es doble (un componente variable por uso y la dependencia de la conectividad para la interpretación), pero la actuación crítica permanece en el borde, de modo que esa dependencia no compromete la operación local de impresión.

2.4. Herramientas de almacenamiento y visualización

En esta sección se presentan las herramientas de persistencia de datos y los componentes destinados a la visualización de la operación, que comprenden las bases de datos que sostienen la información del sistema y el servidor local junto con el panel web de control.

2.4.1. Bases de datos

La información de pedidos, clientes y productos se almacena en PostgreSQL [25], una base de datos relacional de código abierto. Su modelo relacional con integridad referencial resulta adecuado para el dominio del problema, donde los pedidos se vinculan con clientes y con artículos del catálogo. La trazabilidad exigida al sistema requiere garantías de consistencia transaccional, y las consultas sobre el historial alimentan además las métricas del panel de control.

De manera complementaria se emplea Redis [26], una base de datos en memoria de tipo clave-valor, para la gestión de las sesiones y del estado de los clientes activos durante la recepción de un pedido. Redis ofrece tiempos de acceso muy bajos y expiración automática de claves, características apropiadas para datos de carácter transitorio con alta frecuencia de lectura y escritura. La combinación responde a un criterio de diseño explícito: los datos persistentes y auditables residen solo en la base relacional, mientras que Redis se reserva para información temporal, de modo que una eventual falla de la capa en memoria no compromete los registros del negocio.

2.4.2. Servidor local y panel de visualización

El servidor de impresión que se ejecuta en el nodo de borde se implementó sobre Flask [27], un entorno de desarrollo web minimalista escrito en el lenguaje Python [28]. Flask permite exponer servicios HTTP con una huella de recursos reducida y sin la complejidad de un servidor de aplicaciones completo. Resulta adecuado para un servicio local de propósito específico, que recibe el pedido estructurado y comanda la impresora sobre el equipo Windows del comercio.

La visualización de los pedidos, del historial y de las métricas de operación se ofrece a través de un panel web alojado en el VPS, accesible desde cualquier navegador moderno. Este enfoque evita la instalación de aplicaciones adicionales en los dispositivos del comercio. El panel se desarrolló con Angular [29], un entorno de desarrollo de aplicaciones web mantenido por Google, junto con la biblioteca de componentes Angular Material. La representación de las métricas se resuelve con Chart.js [30]. La elección de un entorno estructurado, con tipado estático y organización por componentes, respondió a la necesidad de sostener el crecimiento del panel a medida que se incorporan nuevas vistas y funciones de administración.

Capítulo 3

Diseño e implementación

En el presente capítulo se describen el diseño y la implementación del sistema. Se presenta la arquitectura general y la distribución del cómputo entre el comercio y la nube.

3.1. Arquitectura del sistema

El sistema se organizó en tres capas funcionales. La capa de captura y comunicación recibe los mensajes del canal de mensajería y los prepara para su interpretación. La capa de procesamiento inteligente interpreta el contenido, lo estructura contra el catálogo del comercio y lo persiste. La capa de interacción local e impresión ejecuta la actuación física sobre la impresora del negocio. En la figura 3.1 se presentan las tres capas, sus componentes y el flujo de datos extremo a extremo.




FIGURA 3.1. Arquitectura del sistema en tres capas.

3.1.1. Criterio de distribución del cómputo

El criterio rector del diseño fue asignar cada tarea al lugar de ejecución que mejor equilibra latencia, disponibilidad y costo. Las tareas de mayor demanda de procesamiento son la transcripción de voz, la lectura de imágenes y la estructuración mediante modelos de lenguaje. Todas ellas se delegaron a servicios en la nube, donde la capacidad de cómputo resulta elástica y los modelos se consumen bajo demanda. Ejecutarlas sobre el equipo del comercio habría exigido una inversión en hardware incompatible con las restricciones económicas del trabajo.

La actuación crítica del negocio es la impresión del ticket que habilita el armado del pedido. Esa tarea se resolvió en el borde, sobre el servidor local del comercio. La decisión responde a tres motivos. El primero es la latencia, ya que la orden de impresión recorre un único salto desde el servidor local hasta la impresora. El segundo es la independencia del canal, dado que la impresora nunca se expone a Internet, sino que queda detrás de un servicio local que actúa como intermediario. El tercero es la continuidad operativa, porque el personal puede reimprimir un pedido ya recibido desde el panel sin que intervengan los modelos de inteligencia artificial.

3.1.2. Organización del código

El código fuente se organizó en cuatro módulos independientes, que se corresponden con los componentes de la arquitectura:

- `api/`: la interfaz de programación de aplicaciones (API) y la lógica de pedidos, implementadas con Node.js [31], Express [32] y TypeScript [33] sobre el mapeador objeto-relacional (ORM, del inglés *Object-Relational Mapping*) Prisma [34].
- `web/panel/`: el panel web de control, desarrollado con Angular.
- `n8n/`: los flujos de automatización que orquestan la recepción y la interpretación de los pedidos.
- `print_server/`: el servidor de impresión que se ejecuta en el nodo de borde, implementado con Flask.

Esta separación permite desplegar, actualizar y probar cada módulo por separado. La API y el panel se comunican solo a través de recursos HTTP, sin dependencias de código compartido, de modo que un cambio en la interfaz no obliga a modificar el servidor.

3.1.3. Entorno de desarrollo

El desarrollo planteó una dificultad práctica, dado que la impresora se encuentra en el comercio y permanece en uso durante el horario comercial, por lo que no resultaba viable ensayar contra el equipo real cada modificación del flujo.

La solución adoptada fue una versión simulada del servidor de impresión. Ese componente expone el mismo recurso y acepta el mismo formato de petición que el servidor real, pero en lugar de enviar el ticket a la impresora lo registra en la consola. El archivo de composición de contenedores del entorno de desarrollo inicia la API, el panel y esa versión simulada, y dirige las peticiones de impresión hacia ella de forma automática.

El resultado fue un entorno de desarrollo completo, reproducible en cualquier equipo y sin dependencia del hardware del comercio. La sustitución se resuelve por configuración, sin cambios en el código de la API, lo que garantiza que el componente ejercitado durante las pruebas sea el mismo que opera en producción.

3.1.4. Flujo de datos extremo a extremo

El recorrido de un pedido comprende las siguientes etapas. El cliente envía uno o varios mensajes por WhatsApp. La pasarela Evolution API los entrega al flujo de n8n mediante una notificación automática. El flujo clasifica cada mensaje según su tipo y aplica el procesamiento correspondiente hasta obtener texto plano. Ese texto se acumula en una lista temporal en Redis, asociada al teléfono del cliente, y se agrupa con los mensajes contiguos del mismo remitente. El conjunto agrupado se entrega al agente de inteligencia artificial junto con el catálogo vigente de productos y unidades. El agente devuelve el pedido estructurado. La API lo valida, resuelve los precios aplicables, lo persiste y solicita la impresión. El servidor local recibe el ticket a través del túnel seguro y lo envía a la impresora. En paralelo, el pedido queda disponible en el panel web para su seguimiento.

3.2. Capa de captura y comunicación

Esta capa recibe los mensajes de los clientes y los convierte en un texto único, listo para su interpretación. Constituye la entrada del sistema y concentra una parte importante de la complejidad del procesamiento, ya que debe gestionar la diversidad de formatos y tipos de contenido recibidos a través del canal de mensajería.

3.2.1. Recepción de los mensajes

La recepción se resolvió mediante el mecanismo de notificaciones automáticas de la pasarela Evolution API. Ante cada mensaje entrante, la pasarela emite una petición HTTP hacia el punto de entrada del flujo de n8n. El primer nodo del flujo normaliza la estructura del mensaje recibido y extrae los datos relevantes como el teléfono del remitente, su nombre de perfil, el identificador del mensaje, el tipo de contenido y la marca temporal.

El teléfono cumple una función central en el diseño, ya que opera como identificador natural del cliente a lo largo de todo el flujo. Se utiliza para agrupar los mensajes, como clave de sesión del agente y como criterio de búsqueda del cliente en la base de datos, donde el campo correspondiente tiene restricción de unicidad. La elección resultó natural para el dominio: el número de teléfono es estable, lo provee el propio canal sin intervención del cliente y no requiere ningún registro previo.

El nombre de perfil de WhatsApp, en cambio, resultó insuficiente para identificar al cliente en el negocio. Muchas personas configuran un apodo o dejan el campo vacío, y el comercio conoce a sus clientes por su nombre real o por su razón social. Por ese motivo, el flujo complementa la identificación con una consulta a la agenda de contactos asociada al comercio, y la base de datos conserva un campo propio con el nombre que el personal administra desde el panel.

3.2.2. Clasificación y procesamiento por tipo de contenido

Un mismo pedido puede llegar como texto libre, como uno o varios mensajes de voz, como una fotografía de una lista manuscrita, como una captura de una planilla o como un documento adjunto. El flujo resuelve esa diversidad con un nodo de derivación que evalúa el tipo de contenido y envía el mensaje a la rama correspondiente. En la figura 3.2 se muestra el procesamiento completo de esta capa.




FIGURA 3.2. Procesamiento de la capa de captura, desde el mensaje entrante hasta el texto agrupado.

Los mensajes de texto se emplean de forma directa. Los mensajes de voz y las imágenes requieren un paso previo de descarga. La pasarela entrega el contenido multimedia codificado en base64, que luego se convierte en un archivo binario antes de enviarlo al modelo correspondiente. Los mensajes de voz se transcriben con el servicio de transcripción de OpenAI. Los documentos adjuntos se derivan a una rama específica, que reconoce el formato y extrae su contenido mediante los nodos de extracción de PDF y de planillas de cálculo.

El tratamiento de las imágenes constituye el caso más elaborado. La imagen se envía en paralelo a dos modelos de proveedores distintos, GPT-4o de OpenAI y Claude Sonnet de Anthropic. Ambas lecturas se combinan y se entregan a un tercer modelo, que las compara, corrige las diferencias y devuelve una transcripción única.

La instrucción entregada a los modelos de visión no se limita a transcribir el texto visible. Incorpora reglas del dominio que surgieron de la operación real. La más relevante indica conservar la estructura de las tablas y descartar las filas cuya cantidad pedida sea cero. Esa regla resolvió un caso concreto en que algunos clientes mayoristas envían una planilla con el catálogo completo del comercio y completan solo unas pocas filas. Sin esa instrucción, el modelo transcribía el listado íntegro y el agente generaba un pedido con decenas de productos no solicitados.

3.2.3. Agrupación de mensajes fragmentados

El problema más relevante de esta capa no es la interpretación de un mensaje, sino la determinación de dónde termina un pedido. En el uso real, un cliente rara vez envía su pedido en un único mensaje. Lo habitual es una secuencia de mensajes cortos, con mezcla de texto y audio, enviados en el transcurso de un minuto. Si el sistema procesara cada mensaje por separado, generaría varios pedidos incompletos en lugar de uno correcto.

La solución adoptada consiste en un mecanismo de agrupación por ventana temporal, implementado sobre Redis. Cada texto obtenido se agrega al final de una lista cuya clave es el teléfono del cliente. A continuación, el flujo espera un tiempo determinado. Vencido ese plazo, recupera la lista completa, descarta las entradas inválidas, ordena los elementos por su marca temporal y los concatena en un texto único. La lista se elimina luego para dejar la sesión limpia. Los mensajes que llegan durante la espera se acumulan en la misma lista y quedan incluidos en la agrupación, sin disparar un procesamiento adicional.

La elección de Redis para este mecanismo responde a la naturaleza de los datos involucrados. Se trata de información de carácter transitorio, con alta frecuencia de escritura y lectura, cuya pérdida ante una falla no compromete la operación del negocio. La base relacional se reservó para los datos que sí deben persistir y auditarse.

La ventana se fijó en sesenta segundos. El valor no se eligió a partir del comportamiento de los clientes, sino del tiempo de procesamiento del propio sistema. El intervalo entre el ingreso de un mensaje y la finalización de su procesamiento por los agentes resultó cercano al minuto. Una ventana menor habría cerrado la agrupación antes de que los mensajes previos terminaran de procesarse, con el riesgo de fragmentar el pedido. El valor adoptado constituye una cota conservadora, alineada con la latencia observada. La reducción de ese tiempo de procesamiento permitiría acortar la ventana y, con ella, el tiempo total de respuesta del sistema. Esa optimización se plantea como línea de trabajo futuro en el capítulo 5.

3.3. Capa de red y comunicaciones

Esta capa resuelve la conectividad entre los componentes del sistema. Se describen los tres tramos de comunicación que la integran, la forma en que se vincula el nodo de borde con la nube y el formato de los mensajes que se intercambian entre los servicios.

3.3.1. Tramos de comunicación

La conectividad del sistema comprende tres tramos con características distintas. En la figura 3.3 se presenta la topología de despliegue, con los servicios contenerizados del servidor virtual y los componentes instalados en el comercio.

El primero es el tramo de entrada. La pasarela Evolution API, alojada en el servidor virtual, mantiene la vinculación con la red de WhatsApp y notifica cada mensaje al flujo de n8n mediante peticiones HTTPS, la variante cifrada de HTTP.

El segundo es el tramo interno de la nube. Los servicios contenerizados se comunican entre sí dentro del mismo servidor. El flujo de n8n consulta el catálogo a la




FIGURA 3.3. Topología de despliegue del sistema.

API, esta accede a PostgreSQL, mientras que el panel web consume los mismos recursos expuestos por dicha interfaz. Junto a estos servicios opera Chatwoot [18], una plataforma de gestión de conversaciones que centraliza la bandeja de entrada de WhatsApp. Su integración permite que el personal acceda desde el panel al hilo original de la conversación que dio origen a un pedido, lo que resulta útil ante una interpretación dudosa.

El tercero es el tramo entre la nube y el borde, resuelto mediante el túnel de Cloudflare que se describe en la sección siguiente.

3.3.2. Vinculación con el nodo de borde

La decisión de diseño más relevante de esta capa es el sentido en que se establece la conexión con el comercio. En lugar de exponer el servidor local a Internet mediante la apertura de puertos en el enrutador del negocio, el túnel se establece con una conexión saliente cifrada iniciada desde el propio nodo de borde.

Esta elección tiene tres consecuencias prácticas. La instalación no requiere configurar el equipamiento de red del local, condición decisiva en un comercio sin personal técnico. La red interna del negocio no queda accesible desde el exterior, lo que reduce la superficie de ataque. Y el vínculo se restablece de forma automática tras una interrupción, sin intervención manual.

3.3.3. Formato de los mensajes intercambiados

Los datos que circulan entre los componentes se serializan en formato JSON (del inglés, *JavaScript Object Notation*). El agente de inteligencia artificial produce una estructura fija, que constituye el contrato interno del sistema. El código 3.1 muestra su formato.

```
{
  "is_order": true,
  "items": [
    { "nombre": "Papa", "cantidad": 2, "unidad": "kg" }
  ],
  "aclaraciones": "bien lavadas",
  "productos_no_encontrados": []
}
```

CÓDIGO 3.1. Estructura del pedido devuelto por el agente de interpretación.

El campo `is_order` permite descartar los mensajes que no constituyen un pedido, como saludos o consultas de precio. El campo `items` contiene los productos reconocidos, con la denominación exacta del catálogo. El campo `aclaraciones` recoge las instrucciones y observaciones del cliente. El campo `productos_no_encontrados` registra las menciones que no pudieron asociarse a ningún artículo del catálogo, en lugar de descartarlas sin dejar registro. Esta última decisión resultó importante para la trazabilidad. Un producto solicitado y no reconocido queda registrado y visible para el personal, en vez de desaparecer del pedido.

El segundo contrato relevante es el del servidor de impresión. El código 3.2 muestra la petición que la API envía al nodo de borde.

```
POST /print
X-Printer-Token: <token>

{
  "text": "PEDIDO\n...",
  "printer_name": "Hasar_USB",
  "cut": true,
  "text_size": "double_width"
}
```

CÓDIGO 3.2. Petición de impresión enviada al servidor local.

El campo `text` contiene el ticket ya compuesto. Los campos restantes controlan el destino y el formato de impresión: el nombre de la impresora instalada, el corte automático del papel al finalizar y el tamaño de la tipografía. De manera alternativa, la petición admite una dirección IP y un puerto, para el caso en que la impresora se conecte por red. Esa previsión permite trasladar la impresora dentro del local sin modificar el código, tal como se anticipó en el capítulo 2.

El servidor de impresión resuelve el envío según la plataforma sobre la que se ejecuta. En Windows utiliza la interfaz de impresión del sistema operativo en modo directo, lo que evita que el controlador reinterprete el contenido y preserva los comandos ESC/POS. En sistemas Linux delega en el sistema de impresión estándar, y ante una impresora de red abre una conexión directa al puerto correspondiente. Esta triple implementación permitió desarrollar y ensayar el componente fuera del entorno del comercio.

3.4. Capa de aplicación y procesamiento

Esta capa concentra la interpretación de los pedidos, su validación, la resolución de precios y su persistencia. Es la de mayor complejidad lógica y la que resuelve el problema central del trabajo.

3.4.1. Interpretación mediante agentes de inteligencia artificial

La interpretación se implementó como un agente de inteligencia artificial orquestado en n8n. El agente recibe cuatro insumos: el texto agrupado del cliente, sus datos de contacto, el catálogo vigente de productos y la lista de unidades admitidas. Los dos últimos no están fijados en el flujo, sino que se consultan a la API en cada ejecución mediante recursos internos previstos para ese fin. Esta decisión evita la duplicación del catálogo y el personal lo administra desde el panel. De esta forma, el agente siempre opera con la versión actualizada.

El agente cuenta además con memoria de ventana, cuya clave de sesión se construye a partir del teléfono del cliente. De este modo, cada conversación mantiene su contexto de forma independiente.

El comportamiento del agente se define mediante un mensaje de sistema, es decir, la instrucción permanente que delimita su rol y sus reglas antes de recibir cada mensaje del cliente. Su redacción constituyó una parte sustancial del desarrollo, porque de ella dependen tanto la calidad de la interpretación como la estabilidad del formato de salida. El código 3.3 reproduce sus fragmentos más representativos.

```
# ROL
Sos un asistente para una verduleria. Tu unica tarea es:
1. Determinar si el mensaje del cliente es un pedido de compra.
2. Extraer los productos, cantidades y unidades solicitados.

# CATALOGO
- Para el campo 'nombre' en cada item, usa exactamente el nombre
  del catalogo.
- Si el cliente menciona un producto que no esta en el catalogo,
  ponelo en 'productos_no_encontrados' (no en 'items').
- Si el cliente usa un apodo o abreviatura que corresponde a un
  producto del catalogo, usa el nombre del catalogo.

# SALIDA
Devuelve unicamente el JSON, sin texto adicional ni marcado.
```

CÓDIGO 3.3. Fragmentos del mensaje de sistema del agente de interpretación.

Tres criterios guiaron esa redacción. El primero es la delimitación estricta del rol, que evita que el agente responda consultas ajenas al pedido. El segundo es la restricción del formato de salida, indispensable para consumir la respuesta de forma programática. El tercero es el tratamiento explícito de los casos ambiguos, que impide que el modelo complete por su cuenta la información faltante.

3.4.2. Normalización semántica de productos

Un problema específico del dominio es la variabilidad con que los clientes nombran un mismo producto. Las denominaciones llegan en plural o singular, con diminutivos, con abreviaturas o con errores de tipeo. El sistema debe asociarlas al artículo correcto del catálogo del comercio.

La normalización se resolvió dentro del propio agente, mediante la entrega del catálogo completo como contexto y una instrucción explícita de correspondencia tolerante a variantes. El agente debe utilizar la denominación exacta del catálogo en el campo de salida. Cuando una mención no admite correspondencia razonable, se deriva al campo de productos no encontrados.

Se consideró como alternativa una normalización previa por reglas o por similitud de cadenas. Esa opción se descartó por dos razones. La primera es que las reglas exigen mantenimiento manual ante cada producto nuevo o cada variante no prevista. La segunda es que la similitud de cadenas resuelve mal los casos en que la diferencia es semántica y no ortográfica, como una denominación regional que no comparte raíz con el nombre del catálogo. La estrategia adoptada traslada esa responsabilidad al modelo, que dispone del catálogo completo y del contexto del mensaje.

3.4.3. Recursos de la interfaz de programación

La API se organizó por recursos, con un prefijo común y un archivo de rutas por entidad. En la tabla 3.1 se resumen los grupos de recursos y su mecanismo de acceso.

TABLA 3.1. Grupos de recursos de la interfaz de programación.

Recurso	Función	Acceso
/auth	Autenticación de personas	Público
/pedidos	Creación, consulta y edición	Clave de servicio o testigo
/productos	Catálogo de productos	Testigo (catálogo: clave)
/unidades	Unidades de medida	Testigo (catálogo: clave)
/categorias	Categorías de productos	Testigo, rol administrador
/clientes	Clientes y listas de precios	Testigo
/precios_default	Precios generales	Testigo
/print-logs	Historial de impresiones	Testigo
/metricas	Indicadores de operación	Testigo
/usuarios	Usuarios del sistema	Testigo, rol administrador

La creación de un pedido desde el flujo automático y su creación desde el panel se resolvieron con recursos distintos, aunque compartan la lógica de persistencia. La separación responde a que difieren en su origen, en su mecanismo de autenticación y en la validación aplicada. El flujo entrega productos ya normalizados por el agente, mientras que el panel recibe datos ingresados por una persona.

3.4.4. Modelo de datos

La persistencia se resolvió sobre PostgreSQL, con acceso mediante el ORM Prisma. El esquema se controla por migraciones versionadas, lo que permite reproducir la estructura de la base en cualquier entorno. En la figura 3.4 se presenta el diagrama entidad-relación con las entidades principales.




FIGURA 3.4. Diagrama entidad-relación de la base de datos.

El núcleo del modelo lo constituyen las entidades `clientes`, `pedidos` e `items_pedido`. Un cliente se identifica por su teléfono, con restricción de unicidad, y acumula sus pedidos. Cada pedido registra la fecha, el estado, las aclaraciones y el mensaje original recibido por WhatsApp. Este último campo resulta clave para la trazabilidad, ya que permite contrastar el pedido estructurado contra el texto que le dio origen.

La entidad `items_pedido` presenta una particularidad de diseño. Junto a la referencia al producto del catálogo conserva un campo con la denominación original empleada por el cliente. Cuando la referencia al catálogo queda vacía, el ítem corresponde a un producto no reconocido. Esos ítems no se descartan: se conservan, se imprimen en una sección separada del ticket y se destacan visualmente en el panel para que el personal decida cómo proceder.

El estado del pedido se modeló como una enumeración con cuatro valores: recibido, en preparación, listo y entregado. La enumeración impide que la base admita estados no previstos y ordena el recorrido operativo del pedido dentro del comercio.

El modelo contempla además dos operaciones propias del uso real. La primera es la fusión de pedidos: cuando un cliente envía un pedido complementario poco después del primero, el personal puede unificarlos desde el panel. El modelo conserva la referencia al pedido resultante y la marca temporal de la operación, lo que permite deshacerla sin pérdida de información. La segunda es la marca de pedido visto, que distingue los pedidos ya revisados por el personal de los que aún esperan atención.

3.4.5. Resolución de precios

La gestión de precios responde a una característica del negocio: no todos los clientes pagan lo mismo. El comercio atiende tanto a consumidores finales como a

otros comercios, con condiciones diferenciadas.

El modelo resuelve esa necesidad mediante listas de precios. Cada cliente puede tener varias listas, y una de ellas se designa como predeterminada. El precio de un ítem se resuelve por orden de prioridad: primero la lista indicada de forma explícita en el pedido, luego la lista predeterminada del cliente y, por último, el precio general del catálogo. Los precios incorporan además vigencia temporal, con fechas de inicio y de fin, lo que permite conservar el histórico sin perder el valor aplicado en cada momento.

Un diseño alternativo, con un único precio por cliente y producto, habría resultado más simple. Se descartó porque impide representar acuerdos comerciales distintos para un mismo cliente, como una condición mayorista y otra minorista, y porque no conserva el histórico de precios necesario para las métricas de facturación.

3.4.6. Generación del ticket

El ticket no se almacena en la base de datos, sino que se compone en el momento de la impresión a partir de los ítems del pedido y de sus aclaraciones. Esta decisión evita la duplicación de información y garantiza que una reimpresión refleje el estado actual del pedido, incluidas las correcciones realizadas por el personal.

La impresión admite dos variantes, con precios y sin precios. El flujo automático imprime sin precios, porque el ticket cumple allí la función de orden de armado. Desde el panel, en cambio, el personal elige la variante al momento de imprimir, según entregue el comprobante al cliente o lo destine al armado interno.

Cada intento de impresión se registra en una entidad específica, con su resultado, la variante utilizada y el mensaje de error en caso de falla. Ese registro cumple dos funciones: permite auditar qué se imprimió y cuándo, y habilita el seguimiento de los errores hasta su resolución. Los pedidos con impresión fallida se destacan en el panel y permanecen señalados hasta que el personal los marca como resueltos, de modo que una falla de la impresora no derive en un pedido sin atender.

3.5. Interfaz de usuario y visualización

El sistema presenta dos interfaces hacia el personal del comercio: el ticket impreso y el panel web de control.

3.5.1. El ticket impreso

El ticket es la salida física del sistema y el insumo directo para el armado del pedido. Su formato es fijo. Incluye un encabezado con los datos del cliente, la lista de productos con cantidades y unidades, una sección separada para los productos no reconocidos, un espacio para las aclaraciones y la fecha y hora del pedido. En la figura 3.5 se presenta un esquema de esos campos. En el anexo A se incluye una imagen de un ticket real generado por el sistema.

80 mm

ENCABEZADO

- Fecha y hora
- Cliente (nombre)
- Teléfono

PRODUCTOS

- Nombre (según catálogo)
- Cantidad y unidad
- Precio unitario (opcional)
- ...

FUERA DE CATÁLOGO

- Productos no reconocidos por el sistema

TOTAL

- Importe total (si lleva precios)

ACLARACIONES

- Observaciones del cliente

FIGURA 3.5. Esquema de los campos que componen el ticket.

El diseño del ticket estuvo condicionado por el medio. El ancho útil del papel es de ochenta milímetros, lo que limita la cantidad de caracteres por línea y obliga a priorizar la información. Por ese motivo, el servidor de impresión admite distintos tamaños de tipografía, que se aplican mediante comandos ESC/POS. Los datos que el personal necesita leer a distancia, en particular el nombre del cliente, se imprimen en tamaño ampliado, mientras que el detalle de los productos se mantiene en tamaño normal para aprovechar el ancho disponible.

3.5.2. El panel web de control

El panel se desarrolló con Angular y la biblioteca de componentes Angular Material. Concentra la operación diaria y la administración del sistema. El acceso está protegido por autenticación, y las vistas de administración quedan restringidas según el rol de la persona que ingresa. En la figura 3.6 se presenta la estructura de navegación del panel.

La navegación se organiza en tres grupos. El primero es la operación diaria, con el tablero de resumen y la gestión de pedidos. El segundo es la administración del catálogo y de los datos comerciales, que reúne los productos, las categorías,




FIGURA 3.6. Estructura de navegación del panel web de control.

las unidades, los clientes y sus listas de precios. El tercero es la visualización de métricas de operación.

El tablero es la vista de entrada y resume el estado de la jornada. Agrupa cuatro bloques de información: los pedidos aún no revisados por el personal, los pedidos recibidos en los últimos minutos, los productos más solicitados en el día y los pedidos con errores de impresión pendientes de resolución. Cada bloque enlaza con la vista de pedidos con los filtros ya aplicados, de modo que una alerta deriva de forma directa en la acción correspondiente.

La gestión de pedidos es la vista de mayor uso durante la jornada. Permite filtrar por estado, por rango de fechas, por pedidos no vistos y por errores de impresión, y admite operaciones sobre varios pedidos a la vez, como el cambio de estado o la marca de revisado. El detalle de cada pedido se abre en un diálogo desde el que el personal corrige cantidades y unidades, agrega o quita ítems, consulta el mensaje original recibido por WhatsApp, accede al hilo de la conversación e imprime o reimprime el pedido. Los ítems que no pudieron asociarse al catálogo se destacan de forma visual, lo que dirige la atención hacia los casos que requieren decisión.

La administración del catálogo reúne los productos, sus categorías y las unidades de medida. Esta gestión resulta crítica, ya que el catálogo es el insumo que el agente utiliza para normalizar las denominaciones, y un producto ausente se traduce de inmediato en ítems no reconocidos. La administración de precios se resuelve en una vista específica, con el listado de listas del cliente a un lado y la tabla de precios editable al otro.

Las métricas de operación se representan con la biblioteca Chart.js e incluyen el tráfico de pedidos por día y hora, la evolución de la facturación por producto y la distribución por categoría. La granularidad de la serie se ajusta de forma automática al rango solicitado, con lo que se evitan gráficos ilegibles por exceso de puntos. El tráfico por día y hora resultó de utilidad directa para el negocio, ya

que expone los momentos de mayor demanda y permite anticipar la asignación de personal.

Las capturas de cada vista del panel se incluyen en el anexo A.

3.6. Seguridad del sistema

La seguridad se abordó en tres frentes: el control de acceso, la protección de las comunicaciones y la integridad de los datos.

3.6.1. Autenticación y control de acceso

El sistema distingue dos tipos de consumidores, con mecanismos de autenticación distintos. Las personas acceden al panel con credenciales y obtienen un testigo de sesión. Los servicios internos, como el flujo de n8n, no disponen de una sesión de usuario y se autentican con una clave de servicio. En la figura 3.7 se representan ambos mecanismos.




FIGURA 3.7. Mecanismos de autenticación para personas y para servicios internos.

Las contraseñas se almacenan cifradas mediante una función de derivación diseñada para ese fin, de modo que la base no conserva las claves en texto plano. Tras una validación exitosa, el sistema emite un testigo firmado con vigencia de ocho horas, que el panel adjunta en cada petición posterior. La vigencia se ajustó a la duración de una jornada comercial, lo que evita tanto la reautenticación durante el turno como la persistencia indefinida de una sesión abierta.

La autorización se implementó por roles. El sistema define tres: administrador, con acceso total; operador, restringido a la operación de pedidos; y consulta, limitado a la lectura. La verificación se resuelve con un componente intermedio que valida el rol antes de ejecutar cada operación, lo que centraliza la regla y evita repetirla en cada recurso. El panel replica esa restricción en sus rutas, de modo que las vistas de administración no resultan accesibles para los roles que no corresponden.

Los recursos internos, como la consulta del catálogo y la creación de pedidos desde el flujo, admiten únicamente la clave de servicio. El recurso de impresión constituye una excepción deliberada, ya que acepta ambas formas de autenticación: la clave de servicio para la impresión automática y el testigo de sesión para la reimpresión desde el panel.

3.6.2. Protección de las comunicaciones

Todo el tráfico externo circula cifrado. La pasarela de mensajería entrega los mensajes por HTTPS y el vínculo entre la nube y el borde se resuelve mediante el túnel descrito en la sección 3.3.2, cuya conexión saliente cifrada evita exponer puertos entrantes en la red del comercio. El servidor de impresión exige, además, un testigo propio en cada petición, de modo que la sola llegada al servicio no habilita la impresión.

3.6.3. Gestión de credenciales e integridad de los datos

Las credenciales de los servicios externos y las claves de firma se gestionan mediante variables de entorno, fuera del código fuente. Los archivos que las contienen quedan excluidos del control de versiones, y el repositorio conserva únicamente valores de ejemplo. Este criterio evita que una credencial operativa quede registrada en el historial del repositorio.

En cuanto a la integridad, el modelo de datos define restricciones de unicidad sobre los campos que identifican a clientes, productos y unidades, y relaciones con integridad referencial entre las entidades. La eliminación de un pedido arrastra sus ítems y sus registros de impresión, lo que evita la persistencia de datos huérfanos. Redis se reservó de manera estricta para información temporal, de modo que una falla en la capa en memoria no compromete los registros del negocio.

Capítulo 4

Ensayos y resultados

En el presente capítulo se describen las pruebas realizadas sobre el sistema y los resultados obtenidos. Se presenta primero el plan de ensayos, con su metodología, sus instrumentos de medición y sus criterios de evaluación. Luego se exponen los ensayos de conectividad y comunicación, los de la capa de aplicación y los de integración extremo a extremo. El capítulo cierra con el análisis de los resultados, las limitaciones detectadas y las mejoras que se desprenden de ellas.

4.1. Plan de ensayos

El plan de ensayos se organizó en dos niveles complementarios. El primero corresponde a la verificación y reúne las pruebas orientadas a comprobar que cada componente fue construido de acuerdo con lo especificado. El segundo corresponde a la validación y reúne las pruebas ejecutadas sobre el sistema en operación real en el comercio, orientadas a comprobar que la solución resuelve el problema planteado.

4.1.1. Alcance y ventanas de medición

La condición particular de este trabajo es que el sistema se desplegó en producción y operó de forma continua durante el período de evaluación. Esa circunstancia permitió sustituir buena parte de los ensayos de laboratorio por mediciones sobre la operación real, con un volumen de casos muy superior al que habría aportado un banco de pruebas construido para la ocasión.

El sistema entró en operación el 1 de junio de 2026 y el primer pedido quedó registrado el 4 de junio. Sobre la ventana comprendida entre esa fecha y el 17 de agosto de 2026 se procesaron 3871 pedidos de 202 clientes, con un total de 29457 ítems y un promedio de 7,61 ítems por pedido.

Las mediciones no cubren todas un mismo intervalo, ya que cada subsistema conserva su información durante un lapso distinto. En la [tabla 4.1](#) se detallan las tres ventanas empleadas y el motivo de su extensión.

TABLA 4.1. Ventanas de medición empleadas en los ensayos.

Aspecto medido	Período	Días	Limitación
Captura e interpretación de pedidos	04/06 17/08/2026	al 75	Inicio de la operación
Impresión automática en el borde	29/06 17/08/2026	al 50	Habilitación de la impresión automática
Ejecuciones de la orquestación	04/08 17/08/2026	al 14	Purga automática de ejecuciones

La diferencia entre la primera y la segunda ventana obedece a la puesta en marcha escalonada de la solución. Durante las cuatro primeras semanas la capa de captura e interpretación operó con el volumen completo de pedidos, pero el comercio aún no contaba con la impresora térmica. En ese período los pedidos interpretados se volcaron a un archivo de texto alojado en un servicio de almacenamiento en la nube, que el personal consultaba de forma manual. Ese mecanismo cumplió una doble función: permitió sostener la operación sin la actuación en el borde y habilitó la revisión sistemática de la calidad de la interpretación antes de automatizar la emisión de tickets.

Una vez adquirida e instalada la impresora, y verificada la correcta interpretación de los pedidos durante ese período de observación, la actuación automática sobre el nodo de borde se habilitó en la semana del 29 de junio. A partir de ese momento el volumen de impresiones se estabilizó por encima de las quinientas operaciones semanales. La decisión de no automatizar la impresión hasta contar con evidencia de la calidad de la interpretación constituyó una medida deliberada de reducción de riesgo operativo.

La tercera ventana responde a una restricción del registro de ejecuciones de la plataforma de orquestación, que conserva las ejecuciones durante catorce días y luego las elimina de forma automática. Sobre ese lapso se registraron 7036 ejecuciones y 789 pedidos.

4.1.2. Instrumentos de medición

La medición se apoyó en tres fuentes de información distintas.

La primera es la base de datos relacional del sistema, que registra cada pedido, cada ítem y cada intento de impresión con su marca temporal y su resultado. La tabla `print_logs` conserva el estado de cada operación de impresión y el mensaje de error asociado, mientras que la ausencia de valor en el campo `producto_id` de la tabla `items_pedido` identifica los ítems que el agente no logró vincular con el catálogo del comercio. Esta fuente aporta la totalidad de la información de las secciones 4.2 y 4.3. Corresponde señalar que la base conserva el pedido ya estructurado y no el mensaje original recibido, que permanece disponible en la plataforma de atención vinculada al canal de mensajería.

La segunda es el registro de ejecuciones de la plataforma de orquestación, que conserva el instante de inicio y de finalización de cada flujo junto con su estado final. Esa información permite acotar el tiempo de interpretación, que no queda registrado en la base relacional del sistema.

La tercera es la plataforma de atención vinculada al canal de mensajería, que conserva cada mensaje entrante con su marca temporal, su contacto de origen y el tipo de contenido de sus adjuntos. Esa fuente aporta la única información disponible sobre el formato del mensaje original, dimensión que las dos anteriores no permiten discriminar, y sostiene la auditoría de la sección 4.4.3. Su vinculación con los pedidos no es directa, ya que ambos sistemas no comparten identificadores, y debió reconstruirse por coincidencia del número de contacto y proximidad temporal según el procedimiento que allí se detalla.

4.1.3. Estrategia de verificación adoptada

Los requerimientos de testing previeron la ejecución de pruebas unitarias sobre los módulos de procesamiento e impresión y de pruebas de integración entre los componentes. La revisión del repositorio confirmó que no se implementaron conjuntos de pruebas automatizadas, más allá del archivo de ejemplo que genera el entorno de desarrollo del panel, que no contiene casos de prueba.

En su reemplazo, la verificación se apoyó en la operación real del sistema durante 75 días. Esa estrategia aporta una cobertura de casos superior a la que habría alcanzado un conjunto de pruebas construido para la ocasión, con la variabilidad propia de los mensajes de clientes reales, y permite validar de forma simultánea la integración de todos los componentes. Su limitación es que no detecta regresiones de manera anticipada ni permite aislar la causa de una falla en un componente determinado, motivo por el que la incorporación de pruebas automatizadas se propone como trabajo futuro en el capítulo 5.

4.1.4. Criterios de evaluación

La planificación del trabajo definió, para cada requerimiento, un método de verificación y un método de validación, pero no estableció valores numéricos de corte con anterioridad al desarrollo. Los ensayos descritos en este capítulo son, en consecuencia, de caracterización: se orientan a determinar el comportamiento efectivo del sistema en operación antes que a contrastarlo contra umbrales preestablecidos.

El criterio de aceptación que operó de manera efectiva fue la validación por parte del cliente en el entorno real. El sistema se incorporó a la operación diaria del comercio y permaneció en uso continuo durante todo el período analizado, lo que constituye una forma de aceptación por uso sostenido. En la sección 4.5.1 se contrasta cada requerimiento contra la evidencia obtenida.

4.2. Ensayos de conectividad y comunicación

Los ensayos de conectividad se orientaron a verificar el vínculo entre la nube y el nodo de borde, que constituye el único punto de contacto entre ambos entornos y, por lo tanto, el eslabón crítico de la cadena. La medición se apoyó en la operación real: cada intento de envío de un ticket hacia el servidor local quedó registrado con su resultado y, en caso de falla, con el mensaje de error devuelto.

4.2.1. Confiabilidad del vínculo en operación

El análisis distingue el período de prueba de la impresora del período de operación automática, ya que las condiciones difieren por completo. Durante las cuatro primeras semanas, cuando el comercio aún no contaba con el equipo, se registraron 39 operaciones de impresión, de las que 13 finalizaron con error. Esos casos carecen de valor para evaluar la confiabilidad del vínculo, dado que el destino de la orden no existía.

Durante el período de operación automática, comprendido entre el 29 de junio y el 17 de agosto, se registraron 4334 operaciones de impresión, de las que 22 finalizaron con error, lo que arroja una tasa de fallas del 0,51 por ciento. En la tabla 4.2 se detalla la clasificación de los errores del período de operación automática según su mensaje y su origen.

TABLA 4.2. Clasificación de los errores registrados durante la operación automática.

Mensaje	Origen	Casos
HTTP 530	Túnel sin origen alcanzable	18
HTTP 502	Pasarela intermedia	2
HTTP 520	Respuesta inválida del origen	1
Fallo de conexión	Red entre la nube y el túnel	1
Total		22

La totalidad de los errores del período de operación automática corresponde a interrupciones del vínculo de comunicación. Los códigos 530 y 520 son emitidos por el proveedor del túnel cuando el extremo local no responde, situación que se produce ante una caída de la conexión a Internet del comercio o ante la detención del proceso en el servidor local. Ningún error se originó en la impresora ni en el formateo del ticket, lo que indica que la actuación física en el borde resultó estable durante todo el período.

Este comportamiento respalda el criterio de distribución del cómputo adoptado en la sección 3.1.1. La única dependencia externa del proceso de impresión es la llegada de la orden desde la nube, y una vez que esa orden alcanza el nodo de borde la operación se completa sin intermediarios.

4.2.2. Análisis de los episodios de pérdida de conectividad

La distribución temporal de los errores resultó más informativa que su recuento. Los 22 casos no se presentaron de forma aislada sino agrupados en episodios de indisponibilidad del vínculo, según se detalla en la tabla 4.3.

Los dos episodios prolongados concentran 14 de los 21 pedidos afectados y presentan un patrón coherente con una interrupción del servicio de Internet en el comercio: fallas consecutivas sobre pedidos distintos, mismo código de error y cese simultáneo al finalizar el episodio. Los casos aislados se resolvieron en plazos que van de los 12 segundos a las 16 horas.

El resultado exige una precisión que corrige la lectura inicial de estos datos. El registro de impresiones incorpora un campo con el que el personal marca un error como atendido, y la totalidad de los casos figura con esa marca. Sin embargo, la

TABLA 4.3. Episodios de pérdida de conectividad registrados durante la operación automática.

Fecha	Duración	Pedidos afectados	Mensaje	Sin ticket
11/07/2026	1 h 12 min	9	HTTP 530	8
13/07/2026	Aislado	1	HTTP 502	0
18/07/2026	Aislado	1	HTTP 520	1
24/07/2026	Aislado	1	Fallo de conexión	0
27/07/2026	Aislado	1	HTTP 530	0
28/07/2026	1 h 25 min	5	HTTP 530	5
29/07/2026	8 min	3	HTTP 502 y 530	1
Total		21		15

verificación de las impresiones anteriores y posteriores a cada error muestra un panorama distinto. Tres de los pedidos afectados ya contaban con un ticket emitido, de modo que la falla se produjo sobre una reimpresión. Otros tres recibieron su ticket con posterioridad al episodio. Los 15 restantes no registran ninguna emisión exitosa, lo que representa el 0,39 por ciento de los 3871 pedidos procesados durante el período. La marca de atención refleja, por lo tanto, la resolución operativa del caso por parte del personal, que consultó el pedido en el panel y lo armó sin comprobante impreso, y no la emisión efectiva del ticket.

La consecuencia de diseño es doble. Por un lado, la indisponibilidad del vínculo no interrumpe la operación del comercio, ya que el pedido permanece accesible en el panel con la totalidad de su información y el personal puede continuar el armado. Por el otro, el sistema carece de un mecanismo de reintento automático que emita los tickets pendientes al restablecerse el enlace, de modo que la recuperación depende de que el personal advierta la situación. Los episodios registrados muestran que el enlace se restablece por sí solo en plazos acotados, lo que vuelve viable la mejora propuesta en la sección [4.5.3](#).

4.3. Ensayos de la capa de aplicación

Los ensayos de la capa de aplicación se orientaron a evaluar dos dimensiones. La primera es la calidad de la interpretación de los pedidos, que constituye la función central del sistema. La segunda es la estabilidad de la plataforma de orquestación que coordina esa interpretación.

4.3.1. Tasa de reconocimiento de ítems

La métrica adoptada para evaluar la interpretación fue la proporción de ítems que el agente logró asociar con un producto del catálogo del comercio. Un ítem no asociado se registra con la denominación original recibida y se destaca en el panel, de modo que la operación continúa pero requiere una decisión del personal.

Sobre un total de 29457 ítems procesados durante los 75 días de operación, 28999 fueron asociados con un producto del catálogo, lo que arroja una tasa de reconocimiento del 98,45 por ciento. Los 458 ítems restantes quedaron sin asociar y se distribuyeron en 213 denominaciones distintas.

La magnitud de la muestra resulta relevante para la interpretación del resultado. La medición no se apoyó en un conjunto de prueba construido para la ocasión, sino en la totalidad de los pedidos recibidos durante la operación real del comercio, con la variabilidad de redacción, ortografía y formato propia de los mensajes de clientes reales.

4.3.2. Análisis de los ítems no reconocidos

Las denominaciones no asociadas se clasificaron mediante su normalización, con supresión de tildes y unificación de mayúsculas, y su posterior comparación contra el catálogo de productos. El análisis permite distinguir ocho situaciones de naturaleza distinta, que se detallan en la tabla 4.4.

TABLA 4.4. Clasificación de los ítems no asociados al catálogo.

Situación	Casos	Porcentaje
Variedades comerciales y códigos de calibre	112	0,38
Producto incorporado al catálogo con posterioridad	94	0,32
Productos de almacén ausentes del catálogo	82	0,28
Denominaciones sin correspondencia interpretable	80	0,27
Frutas y hortalizas ausentes del catálogo	47	0,16
Producto presente en el catálogo pero inactivo	29	0,10
Contenido ilegible en el mensaje de origen	9	0,03
Casos residuales posteriores al alta del producto	5	0,02
Total	458	1,55

La primera situación reúne nombres de variedad y códigos de calibre propios del comercio mayorista de frutas. Las variedades de mandarina Ellendale y Encore concentran 38 casos y la variedad de pera Bosc concentra 18, a los que se suman numerosas denominaciones que combinan variedad, tipo de envase y calibre. Ninguna de ellas integra el catálogo del comercio, que registra los productos con su nombre genérico.

La forma en que esas denominaciones quedaron registradas resulta significativa. La variedad Ellendale aparece bajo nueve escrituras distintas y la variedad Bosc bajo quince, con deformaciones progresivas del tipo *Boschi*, *Boscoli* o *Boschaitis*, que se prolongan hasta el grupo de denominaciones carentes de correspondencia interpretable, integrado por 80 casos repartidos en 68 escrituras distintas. La morfología de esas deformaciones es la propia de una transcripción, y no la de un error de tipeo, lo que sugiere que el conjunto proviene de la lectura de listas con terminología ausente del catálogo, situación en la que el agente carece de referencia para normalizar aquello que interpreta.

Esa lectura constituye una hipótesis sobre el origen del error y no un resultado medido. La auditoría por formato de entrada de la sección 4.4.3 fue diseñada para contrastarla y no la confirma: la tasa de asociación no presenta diferencias apreciables entre los formatos de entrada, de modo que el error residual no se concentra en la modalidad de imagen. Lo que sí distingue a esa modalidad es el tamaño del pedido, según se analiza en dicha sección.

La segunda situación agrupa 94 ítems correspondientes a productos que no integraban el catálogo en el momento del pedido y que fueron incorporados con posterioridad. El caso más ilustrativo es el del huevo, con 55 ocurrencias registradas entre el 10 de junio y el 12 de julio. Ese último día el producto se dio de alta y a partir de entonces no se registró ningún fallo adicional. El patrón se repite en el resto del grupo y evidencia un mecanismo de realimentación operativa: los ítems no reconocidos que el panel destaca orientaron la ampliación progresiva del catálogo por parte del personal del comercio.

La tercera y la quinta situación corresponden a productos que el comercio no comercializa. Entre los de almacén predominan la cúrcuma, con 15 casos, y diversos condimentos. Entre los frescos, el caso de mayor frecuencia es el hongo portobello, con 17 casos, cuya denominación correcta tampoco figura en el catálogo. En ambos grupos la interpretación del agente fue adecuada y la ausencia de asociación refleja una limitación de la cobertura del catálogo.

La sexta situación reúne 29 ítems correspondientes a productos que integran el catálogo pero se encuentran marcados como inactivos, entre los que predominan la miel y el pimentón. El agente recibe únicamente los productos activos, de modo que la baja de un producto que los clientes aún solicitan se traduce de forma directa en ítems no asociados.

La séptima situación corresponde a los mensajes cuyo contenido no pudo leerse, registrados con la marca de contenido ilegible en nueve oportunidades. Este comportamiento responde al diseño del agente, al que se instruyó para señalar la imposibilidad de lectura en lugar de inferir un producto probable. La decisión resultó acertada en el contexto del negocio, donde un ítem incorrecto en el ticket genera un error de armado del pedido, mientras que un ítem señalado como dudoso deriva en una consulta al cliente antes del despacho. Los cinco casos residuales de la última situación se registraron en los días inmediatamente posteriores al alta de un producto.

La conclusión del análisis modifica de manera sustancial la lectura del 1,55 por ciento de ítems no asociados. De los 458 casos, 364 responden a la cobertura del catálogo, ya sea por productos ausentes, por variedades comerciales no contempladas o por productos dados de baja, y 9 corresponden a contenido ilegible señalado de forma deliberada. Únicamente los 80 casos sin correspondencia interpretable son atribuibles a un error de interpretación, lo que representa el 0,27 por ciento de los ítems procesados y sitúa la exactitud efectiva de la interpretación en el 99,73 por ciento.

4.3.3. Estabilidad de la orquestación

La plataforma de orquestación coordina la recepción de los mensajes, la invocación de los modelos de interpretación y la persistencia de los pedidos. Su registro de ejecuciones permite evaluar la estabilidad del conjunto. En la tabla 4.5 se resumen las ejecuciones registradas durante la ventana de catorce días.

Sobre 7036 ejecuciones se registraron 7 fallas, lo que arroja una tasa de error del 0,10 por ciento. Ese valor verifica el requerimiento de integración entre los componentes, ya que cada ejecución del flujo de interpretación involucra al canal de mensajería, a la base en memoria, a los servicios de inteligencia artificial y a la base relacional.

TABLA 4.5. Ejecuciones registradas por flujo de orquestación.

Flujo	Correctas	Con error	Duración media
Interpretación de pedidos	6710	2	36,31 s
Confirmación de pedidos	299	4	0,87 s
Sincronización de contactos	13	1	3627,05 s
Gestión de errores	7	0	0,49 s
Total	7029	7	

La duración media del flujo de interpretación no debe leerse como tiempo de procesamiento, según se analiza en la sección 4.4.2.

El flujo de sincronización de contactos, que actualiza de forma programada los nombres de los clientes a partir de la agenda del comercio, presenta una duración media del orden de la hora, con trece ejecuciones en catorce días. Ese valor no refleja un costo de cómputo sino las esperas deliberadas que el flujo intercala entre lotes para respetar los límites de tasa de las interfaces que consume. Al operar de forma desacoplada del flujo de pedidos, no incide sobre la latencia percibida por el comercio.

4.4. Ensayos de integración extremo a extremo

Los ensayos de integración evalúan el recorrido completo del pedido, desde la recepción del mensaje hasta la emisión del ticket en el comercio. El análisis se organiza en dos partes. La primera mide la latencia de la actuación en el borde, que es la etapa que el diseño buscó optimizar. La segunda descompone la latencia total y acota la contribución de cada tramo.

4.4.1. Latencia de la actuación en el borde

Se midió el tiempo transcurrido entre la persistencia del pedido en la base de datos y la emisión de su primer ticket. En la figura 4.1 se presenta la distribución obtenida sobre 2606 pedidos.

La distribución resultó marcadamente bimodal. El 98,58 por ciento de los casos se resolvió en menos de cinco segundos y el 1,38 por ciento superó el minuto, mientras que en el intervalo intermedio, que abarca casi un minuto completo, se registró un único caso. Esa discontinuidad indica la presencia de dos poblaciones de naturaleza distinta y permite separarlas mediante un umbral de cinco segundos, cuya ubicación dentro de un intervalo vacío vuelve irrelevante la elección precisa del valor.

La primera población corresponde a la impresión automática que el sistema dispara al persistir el pedido. La segunda corresponde a la reimpresión diferida que el personal ejecuta desde el panel, en general con precios incluidos, en el momento del despacho. Esa interpretación se confirma al observar que 1321 pedidos registraron exactamente dos impresiones, cantidad superior a los 1113 pedidos con una sola, y que 1621 de las impresiones correctas se emitieron con precios frente a 2717 sin ellos. La doble emisión responde al flujo operativo del comercio, que utiliza un ticket sin precios para el armado del pedido y otro con precios para su entrega.




FIGURA 4.1. Distribución del tiempo transcurrido entre la persistencia del pedido y su primera impresión.

En la tabla 4.6 se presentan las métricas correspondientes a la población de impresión automática.

TABLA 4.6. Latencia de la impresión automática en el nodo de borde.

Métrica	Valor
Casos analizados	2569
Mínimo	0,110 s
Media	0,425 s
Mediana	0,338 s
Percentil 95	0,921 s
Percentil 99	1,475 s
Máximo	4,220 s

El resultado más significativo no es la mediana sino la dispersión. El peor caso registrado en cincuenta días de operación fue de 4,22 segundos, y la coincidencia entre media y mediana indica una distribución sin cola apreciable. La actuación física del sistema resultó, por lo tanto, no solo rápida sino predecible.

Ese comportamiento es consecuencia directa del criterio de distribución del cómputo. La orden de impresión recorre un único salto dentro de la red del comercio y no atraviesa Internet, de modo que su latencia queda determinada por la red local y por el tiempo de respuesta de la impresora.

4.4.2. Composición de la latencia extremo a extremo

La latencia total percibida por el comercio se compone de dos tramos. El primero abarca desde la recepción del mensaje hasta la persistencia del pedido y se resuelve en la nube. El segundo abarca desde la persistencia hasta la emisión del ticket y se resuelve en el borde, con los valores de la sección anterior.

El primer tramo se midió a partir de la duración de las ejecuciones del flujo de interpretación. En la figura 4.2 se presenta su distribución.




FIGURA 4.2. Distribución de la duración de las ejecuciones del flujo de interpretación de pedidos.

La distribución vuelve a presentar dos poblaciones separadas por un intervalo vacío. El 47,39 por ciento de las ejecuciones finalizó en menos de cinco segundos y el 52,61 por ciento restante superó los sesenta, sin ningún caso registrado entre ambos valores.

La explicación se encuentra en el mecanismo de agrupación de mensajes descrito en la sección 3.1.1. Ese mecanismo no impone una espera fija sino una espera por inactividad. Cada mensaje entrante se incorpora a una lista asociada al cliente y la ejecución aguarda sesenta segundos antes de reevaluar el estado de esa lista. Si durante ese lapso llegó un mensaje posterior, la ejecución concluye sin procesar y delega la interpretación en la ejecución más reciente. Si no llegó ninguno, procede a interpretar el conjunto completo y elimina la lista.

La distribución permite entonces distinguir tres comportamientos. Las 3180 ejecuciones que finalizaron en menos de cinco segundos corresponden a mensajes descartados por los filtros previos, que excluyen los mensajes de grupos y los emitidos por el propio comercio. Las 1744 comprendidas entre sesenta y sesenta y dos segundos corresponden a mensajes sucesivos de un mismo pedido, que concluyeron al detectar la llegada de un mensaje posterior. Las 1786 restantes son las que ejecutaron efectivamente la interpretación, y de ellas 1405 completaron el procesamiento en menos de quince segundos adicionales a la espera, 301 lo hicieron entre quince y sesenta, 79 entre sesenta y doscientos cuarenta, y una sola superó ese valor.

El tiempo de cómputo de la interpretación se ubica, por lo tanto, en el orden de las unidades de segundo. La demora dominante en el tramo que se resuelve en la nube no proviene del procesamiento sino de la espera deliberada por inactividad del cliente.

El contraste entre ambos tramos constituye el resultado central del trabajo. La etapa que depende de servicios remotos admite una espera de sesenta segundos porque su restricción no es de latencia sino de completitud del pedido, mientras que la etapa que ejecuta la actuación física en el borde opera con un máximo de 4,22 segundos y una mediana inferior al medio segundo. La distribución del cómputo asignó a cada entorno la tarea que mejor se ajusta a sus características.

Corresponde precisar qué unidad mide esta distribución. Durante la ventana analizada, 1786 ejecuciones completaron la interpretación frente a 789 pedidos persistentes, lo que arroja una relación de 2,26 ejecuciones por pedido. El origen de esa relación se verificó reconstruyendo, sobre el registro de la plataforma de atención, las agrupaciones de mensajes que el mecanismo de espera por inactividad habría formado en esa misma ventana. Con el criterio de corte de sesenta segundos a los 3386 mensajes entrantes recibidos de contactos individuales, la reconstrucción arroja 1893 agrupaciones; con un corte de noventa segundos, que absorbe la latencia de ingreso de cada mensaje, arroja 1801. Ese valor difiere en menos del uno por ciento de las 1786 ejecuciones que efectivamente interpretaron.

La coincidencia establece que cada ejecución de interpretación corresponde a una conversación agrupada y no a un pedido. Las 997 conversaciones restantes son intercambios que superaron los filtros previos pero no derivaron en un encargo, como consultas de precio, confirmaciones y saludos. La duración medida es, en consecuencia, la del procesamiento de una conversación, y el sistema resuelve algo más del doble de conversaciones que de pedidos.

4.4.3. Auditoría por formato de entrada

El requerimiento de admitir pedidos en texto, voz, imagen y documento exige comparar el comportamiento del sistema entre esas cuatro modalidades. Ninguna de las dos primeras fuentes de medición lo permite, ya que la base relacional conserva el pedido ya estructurado y no el mensaje que lo originó. La comparación se construyó, en consecuencia, sobre el registro de la plataforma de atención, que sí conserva el tipo de contenido de cada mensaje entrante.

Reconstrucción del vínculo entre mensaje y pedido

Los dos sistemas no comparten identificadores, de modo que la correspondencia entre un mensaje y el pedido que produjo debió reconstruirse. El procedimiento aprovecha el mecanismo de agrupación por inactividad descrito en la sección 4.4.2: dado que el flujo persiste el pedido una vez transcurrida la espera sin nuevos mensajes, todo pedido debe estar precedido por un mensaje del mismo contacto a una distancia próxima a esa espera. Se emparejó entonces cada pedido con el último mensaje entrante recibido del mismo número de contacto con anterioridad a su registro.

La distribución de esas distancias confirma la validez del emparejamiento. La mediana es de 72 segundos, con un primer cuartil de 68 y un tercer cuartil de 85, valores que reproducen la espera de sesenta segundos más el tiempo de procesamiento. Se consideraron atribuibles los pedidos cuyo mensaje precedente se ubica a no más de 120 segundos, criterio que alcanza a 3038 de los 3871 pedidos de la ventana, es decir el 78,48 por ciento. Para cada uno de ellos se reconstruyó además la agrupación completa, que encadena hacia atrás los mensajes separados por menos de noventa segundos, y se asignó al pedido el formato de los adjuntos presentes en esa agrupación.

La cobertura del emparejamiento se mantiene estable a lo largo de todo el período, con una mediana diaria del 79 por ciento y un mínimo del 61 por ciento, sin días de cobertura anómala. Esa uniformidad permite descartar que el subconjunto atribuido corresponda a un tramo particular de la operación y sostiene su uso como muestra del conjunto.

Composición del tráfico y resultados por formato

Durante la ventana de 75 días se recibieron 16619 mensajes entrantes de contactos individuales, con la siguiente distribución por formato: 77,39 por ciento de texto, 12,41 por ciento de audio, 8,29 por ciento de imagen, 1,78 por ciento de documento y 0,14 por ciento de video. Las cuatro modalidades previstas por el requerimiento se presentan, por lo tanto, en la operación real y con volumen suficiente para ser comparadas, con la salvedad del video, cuya presencia es marginal.

En la tabla 4.7 se presentan los resultados de la auditoría sobre los 3038 pedidos atribuidos. La categoría mixta reúne los pedidos cuya agrupación combina adjuntos de más de un tipo.

TABLA 4.7. Auditoría por formato de entrada sobre los pedidos atribuidos.

Formato	Pedidos	%	Ítems	Tasa de asociación	Ítems/pedido
Texto	2013	66,26	12060	99,17	5,99
Audio	563	18,53	2952	99,32	5,24
Imagen	405	13,33	4727	99,30	11,67
Mixto	40	1,32	321	98,75	8,03
Documento	16	0,53	424	98,11	26,50
Video	1	0,03	1	100,00	1,00
Total	3038	100,00	20485	99,19	6,74

El resultado principal es la ausencia de diferencias apreciables en la tasa de asociación entre las tres modalidades de volumen significativo. El texto alcanza el 99,17 por ciento, el audio el 99,32 y la imagen el 99,30, valores comprendidos en un intervalo de 0,15 puntos porcentuales. El documento presenta el valor más bajo, 98,11 por ciento, pero sobre una base de 16 pedidos que no admite generalización. La interpretación multimodal no introduce, en consecuencia, una penalización medible respecto del texto plano, que constituye el resultado de mayor relevancia para el requerimiento.

El segundo resultado es que el formato sí determina el tamaño del pedido. Un pedido enviado por texto contiene en promedio 5,99 ítems y uno enviado por audio 5,24, mientras que uno enviado por imagen contiene 11,67 y uno enviado como documento 26,50. Las modalidades de imagen y documento concentran los pedidos extensos, que son los que el comercio recibe como lista completa de reposición, y su aporte al volumen total de ítems resulta muy superior al que sugiere su participación en la cantidad de pedidos: la imagen representa el 13,33 por ciento de los pedidos pero el 23,08 por ciento de los ítems.

La combinación de ambos resultados corrige la lectura planteada como hipótesis en la sección 4.3.2. El error residual no se concentra en la modalidad de imagen. Lo que la imagen concentra son los pedidos extensos con terminología de proveedor, de modo que la asociación entre listas manuscritas y denominaciones no interpretables responde al contenido de esos pedidos y no a una degradación de la interpretación por el hecho de provenir de una fotografía.

Limitaciones de la auditoría

Tres limitaciones acotan el alcance de estos resultados y deben declararse de forma explícita.

La primera es que el indicador empleado es la tasa de asociación de los ítems con el catálogo, no la exactitud de la interpretación. Un ítem asociado a un producto puede haber sido interpretado con una cantidad o una unidad incorrectas, y ese error no queda registrado en ninguna de las fuentes disponibles. La verificación de los tres atributos de manera independiente exigiría contrastar cada pedido contra el contenido del mensaje original, tarea que sobre el volumen analizado solo sería viable por muestreo manual.

La segunda es que el tiempo extremo a extremo no puede desagregarse por formato. El instante de llegada del mensaje se conserva en la plataforma de atención y el de persistencia del pedido en la base relacional, pero el registro de ejecuciones no discrimina la modalidad procesada, de modo que no es posible aislar el costo de la transcripción de audio o de la lectura de imagen dentro de la latencia total.

La tercera es que el 21,52 por ciento de los pedidos de la ventana no pudo atribuirse a ningún mensaje próximo. Ese conjunto presenta pedidos de mayor tamaño, con 10,78 ítems por pedido, y una tasa de asociación inferior, del 96,75 por ciento, de modo que su exclusión eleva el valor global de la muestra auditada por encima del 98,45 por ciento del conjunto completo. La comparación entre formatos no resulta afectada, ya que el sesgo opera sobre todas las modalidades por igual, pero los valores absolutos de la tabla 4.7 no deben leerse como la tasa de asociación del sistema, que es la reportada en la sección 4.3.2.

4.4.4. Trazabilidad del pedido

La trazabilidad se verificó de forma estructural. Cada pedido conserva el conjunto de ítems interpretados, con su denominación original cuando no pudieron asociarse al catálogo, el texto exacto enviado a la impresora y el registro completo de los intentos de impresión con su resultado, su marca temporal y su eventual mensaje de error. El panel permite además acceder desde cada pedido al hilo de la conversación que le dio origen.

La consecuencia práctica de ese diseño es que la totalidad de las mediciones presentadas en este capítulo pudo obtenerse a partir de la propia base de datos del sistema, sin instrumentación adicional. La trazabilidad no solo satisface el requerimiento correspondiente, sino que constituyó el instrumento de medición principal del trabajo.

La cadena presenta, sin embargo, una discontinuidad. El mensaje original recibido del cliente no se persiste en la base relacional, que almacena el pedido ya estructurado, sino que permanece únicamente en la plataforma de atención vinculada al canal de mensajería. La reconstrucción del recorrido completo exige, en consecuencia, consultar dos sistemas distintos.

4.5. Análisis de resultados

4.5.1. Verificación de los requerimientos

En la tabla 4.8 se resume el grado de cumplimiento de los requerimientos verificables mediante los ensayos descriptos.

TABLA 4.8. Verificación de los requerimientos a partir de los ensayos realizados.

Req.	Evidencia	Resultado
1.2	Auditoría por formato de entrada	Cuatro formatos en operación; tasa de asociación entre 99,17 y 99,32 por ciento sin diferencia entre texto, audio e imagen
1.3	Tasa de asociación de ítems con el catálogo	98,45 por ciento sobre 29457 ítems
1.6	Operaciones de impresión y pedidos sin ticket emitido	99,49 por ciento sobre 4334 operaciones; 15 pedidos sin ticket, equivalentes al 0,39 por ciento
1.7	Episodios de pérdida del vínculo con el borde	7 episodios en 50 días, 21 pedidos afectados
1.11	Registro de ítems, ticket e impresiones	Verificado con una discontinuidad
3.1	Pruebas unitarias automatizadas	No implementadas
3.2	Tasa de error de la orquestación	0,10 por ciento sobre 7036 ejecuciones
3.3	Operación en el comercio durante 75 días	3871 pedidos de 202 clientes
3.4	Impresiones sin fallas atribuibles a la impresora	Verificado
3.5	Latencia de la actuación en el borde	Mediana de 0,338 s

4.5.2. Limitaciones detectadas

El conjunto de ensayos permitió identificar seis limitaciones.

La primera es la dependencia del sistema respecto del estado del catálogo. La cobertura incompleta y la baja de productos vigentes explican 364 de los 458 ítems no asociados, es decir el 79,48 por ciento. Ese conjunto reúne los productos incorporados con posterioridad, los de almacén y los frescos ausentes, los dados de baja y las variedades comerciales y códigos de calibre, que se retoman en la limitación siguiente por constituir un caso de naturaleza propia dentro de esa misma causa. El sistema carece de un mecanismo que anticipe esa condición, de modo que la incorporación de productos ocurre siempre con posterioridad al primer pedido que los solicita.

La segunda es la cobertura del catálogo frente a la terminología del comercio mayorista. Las variedades y los códigos de calibre que aparecen en las listas de proveedor no tienen correspondencia en el catálogo, que registra los productos con

su nombre genérico, y concentran 112 casos. Sumados a las 80 denominaciones sin correspondencia interpretable, que no responden a la cobertura del catálogo sino a la lectura del mensaje de origen, alcanzan el 41,92 por ciento de los ítems no asociados. La distinción es relevante porque ambos grupos exigen medidas distintas: los primeros se resuelven con la ampliación del catálogo, mientras que los segundos dependen de la calidad del mensaje recibido.

La tercera es la ausencia de un mecanismo de reintento automático de la impresión. Los episodios de pérdida de conectividad dejaron 15 pedidos sin ticket emitido, equivalentes al 0,39 por ciento del total procesado, y su recuperación quedó a cargo del personal, que debió advertir la situación y resolver el armado sin comprobante.

La cuarta es la ausencia de un registro del instante de recepción del mensaje y del formato de origen en la base de datos del sistema. Esa omisión impide medir la latencia extremo a extremo de forma directa y comparar el desempeño entre modalidades de entrada, y obliga a reconstruir el primer tramo a partir del registro de ejecuciones de la orquestación, que se purga cada catorce días. La misma omisión introduce la discontinuidad en la cadena de trazabilidad señalada en la sección 4.4.4.

La quinta es la ausencia de identificación del operador en el registro de impresiones. El campo previsto para ese fin permaneció sin valor en la totalidad de los casos, de modo que la distinción entre la impresión automática y la reimpresión manual debió inferirse a partir de la distribución de las latencias en lugar de leerse de forma directa.

La sexta es la ausencia de pruebas automatizadas, señalada en la sección 4.1.3, que impide detectar regresiones de manera anticipada.

4.5.3. Mejoras propuestas

De las limitaciones anteriores se desprenden seis mejoras concretas, que se retoman en el capítulo 5.

La primera es la incorporación al panel de una vista específica de ítems no asociados, ordenada por frecuencia, que permita al personal dar de alta los productos faltantes de forma sistemática en lugar de reactiva. La medición indica que 123 de los 458 casos, equivalentes al 0,42 por ciento de los ítems procesados, se habrían evitado mediante la incorporación oportuna de productos que luego se dieron de alta o que se encontraban dados de baja. Corresponde asimismo revisar el criterio de baja de productos, ya que los clientes aún solicitan artículos que fueron desactivados.

La segunda es la incorporación al catálogo de las variedades comerciales y de los códigos de calibre empleados por los proveedores, junto con su vinculación al producto genérico correspondiente. Esa ampliación permitiría interpretar las listas de proveedor con el mismo nivel de precisión que los pedidos de los clientes minoristas.

La tercera es la implementación de una cola de impresiones pendientes, con reintento automático al restablecerse el vínculo. Los episodios registrados muestran que la indisponibilidad del enlace se resuelve por sí sola en plazos acotados, de

modo que un reintento diferido habría emitido los 15 tickets faltantes sin intervención del personal. Se trata de la mejora de mayor impacto sobre la confiabilidad percibida del sistema.

La cuarta es la incorporación del instante de recepción del mensaje, del formato de origen y de una referencia al mensaje original a la tabla de pedidos. Esa modificación permitiría medir la latencia extremo a extremo y el desempeño por formato de manera permanente, y cerraría la discontinuidad de la cadena de trazabilidad.

La quinta es el registro efectivo del operador que dispara cada impresión desde el panel, lo que separaría de forma explícita las dos poblaciones que este capítulo debió distinguir por inferencia.

La sexta es la revisión del intervalo de espera por inactividad. La medición demostró que el tiempo de interpretación se ubica en el orden de las unidades de segundo, muy por debajo de los sesenta segundos que dura cada ciclo de espera. Dado que 1744 de las 3530 ejecuciones que ingresaron al mecanismo concluyeron sin procesar por la llegada de un mensaje posterior, la reducción del intervalo disminuiría la latencia percibida en los pedidos enviados en un único mensaje sin afectar la correcta agrupación de los pedidos fragmentados. Una medición previa de la distribución del tiempo entre mensajes sucesivos de un mismo cliente permitiría ajustar ese valor con fundamento empírico.

Capítulo 5

Conclusiones

En el presente capítulo se valora el trabajo realizado a la luz de los objetivos planteados y de la evidencia reunida en el capítulo 4. Se analiza el grado de cumplimiento de los requerimientos, la fidelidad de la ejecución respecto de la planificación original, el comportamiento de los riesgos identificados y la utilidad de las técnicas empleadas. El capítulo cierra con las líneas de trabajo que se desprenden de los resultados obtenidos.

5.1. Conclusiones generales

El trabajo produjo un sistema que se encuentra en operación continua en el comercio para el que fue concebido. Esa circunstancia constituye el principal aporte, ya que los resultados presentados no provienen de un banco de pruebas sino del uso sostenido por parte de sus destinatarios durante 75 días, con 3871 pedidos de 202 clientes y 29457 ítems interpretados.

5.1.1. Grado de cumplimiento de los objetivos

Los objetivos específicos formulados en la sección 1.4 se alcanzaron en su totalidad. Los logros concretos son los siguientes:

- Se automatizó la captura de pedidos en las cuatro modalidades que el canal admite. La auditoría de la sección 4.4.3 verificó que texto, audio e imagen se interpretan con tasas de asociación comprendidas entre el 99,17 y el 99,32 por ciento, sin penalización medible de las modalidades multimodales respecto del texto plano.
- Se alcanzó una tasa de asociación de ítems con el catálogo del 98,45 por ciento sobre 29457 ítems, y el análisis de los 458 casos restantes demostró que el 79,48 por ciento de ellos responde a limitaciones de cobertura del catálogo y no a errores de interpretación.
- Se implementó la trazabilidad completa del pedido, que resultó suficiente para obtener la totalidad de las mediciones de este trabajo sin instrumentación adicional.
- Se automatizó la impresión en el borde con una latencia de mediana 0,338 segundos y máximo 4,22 segundos, sobre 4334 operaciones con una tasa de éxito del 99,49 por ciento.

- Se estableció la comunicación segura entre la nube y el nodo de borde mediante un túnel, cuyo comportamiento se caracterizó en 7 episodios de indisponibilidad a lo largo de 50 días.
- Se construyó el panel web, que se incorporó a la operación diaria y que además habilitó el mecanismo de realimentación del catálogo descripto más adelante.
- Se validó el sistema en condiciones reales, criterio de aceptación que operó de manera efectiva mediante el uso sostenido por parte del comercio.

De los requerimientos verificados en la sección 4.5.1, uno solo no se satisfizo: el que preveía la implementación de pruebas unitarias automatizadas. La verificación se resolvió en su reemplazo mediante la operación real, estrategia que aportó una cobertura de casos superior pero que no detecta regresiones de manera anticipada ni permite aislar la causa de una falla. La incorporación de esas pruebas queda como la deuda técnica más relevante del trabajo. Un segundo requerimiento, el de trazabilidad, se verificó con una salvedad: el mensaje original no se persiste en la base relacional, de modo que la reconstrucción del recorrido completo exige consultar dos sistemas distintos.

5.1.2. Fidelidad respecto de la planificación

La ejecución se apartó de la planificación en el ordenamiento de las etapas antes que en su contenido. El historial del repositorio de desarrollo sitúa el inicio de la construcción el 20 de abril de 2026 y su última intervención el 1 de septiembre del mismo año. La actividad no se distribuyó de manera uniforme: se concentró en una primera etapa intensiva durante la segunda quincena de abril, en la que quedó definida la arquitectura, y en un segundo bloque durante junio, que absorbió la mayor parte del desarrollo del panel web. Los meses posteriores registran intervenciones puntuales de ajuste sobre la interfaz de programación y sobre los flujos de orquestación. Corresponde advertir que la frecuencia de las confirmaciones del repositorio documenta la cronología de la construcción, pero no constituye una medida del esfuerzo dedicado, de modo que no permite contrastar el total contra las 600 horas previstas en la planificación.

La desviación de mayor consecuencia fue deliberada y consistió en adelantar la puesta en producción respecto del final del desarrollo. El sistema entró en operación el 1 de junio de 2026 y registró su primer pedido el 4 de junio, cuando el panel web todavía se encontraba en construcción y el comercio aún no contaba con la impresora térmica. Durante las cuatro primeras semanas la capa de captura e interpretación operó con el volumen completo de pedidos mientras los resultados se volcaban a un archivo de texto que el personal consultaba de forma manual. La automatización de la impresión se habilitó recién el 29 de junio, una vez verificada la calidad de la interpretación.

El efecto de esa decisión fue favorable en dos sentidos. Redujo el riesgo de la puesta en marcha, ya que ningún fallo de interpretación pudo traducirse en un ticket erróneo durante el período de observación, y aportó cuatro semanas de datos reales que orientaron la ampliación del catálogo antes de que el sistema operara de forma autónoma. Su costo fue una mayor carga operativa para el personal durante ese lapso.

5.1.3. Comportamiento de los riesgos identificados

De los cinco riesgos previstos en la planificación, dos se manifestaron durante el período de operación.

El riesgo de fallas de integración entre la plataforma de orquestación, la interfaz de programación y los servicios de inteligencia artificial no se materializó. Sobre 7036 ejecuciones se registraron 7 fallas, equivalentes al 0,10 por ciento, y cada una de esas ejecuciones involucra a la totalidad de los componentes de la cadena.

El riesgo de caídas del servidor local de impresión sí se manifestó, y constituye el caso en que el plan de mitigación resultó inefectivo por no haberse implementado. Se registraron 7 episodios de pérdida del vínculo en 50 días, que afectaron a 21 pedidos y dejaron 15 sin ticket emitido, equivalentes al 0,39 por ciento de los procesados. La mitigación prevista consistía en un mecanismo de supervisión y reinicio automático del proceso en el nodo de borde, que no llegó a incorporarse. La resolución quedó en consecuencia a cargo del personal, que debió advertir la falta del comprobante y armar el pedido con la consulta del panel. Corresponde señalar que la evidencia recogida sugiere una mitigación más adecuada que la prevista: dado que la indisponibilidad se resuelve por sí sola en plazos acotados, una cola de reintentos en la nube habría emitido los 15 tickets faltantes sin intervención alguna, y lo habría hecho con independencia de la causa de la caída.

El riesgo de baja calidad de los mensajes recibidos se manifestó de forma parcial y con un alcance menor al previsto. Los 458 ítems que el sistema no pudo asociar representan el 1,55 por ciento del total, y de ellos solo 80 corresponden a denominaciones sin correspondencia interpretable. La auditoría por formato demostró además que ese error residual no depende de la modalidad del mensaje, de modo que la interpretación multimodal resultó más robusta de lo que la planificación anticipaba. La mitigación efectiva no fue ninguna de las previstas, sino un mecanismo emergente que se describe en el apartado siguiente.

El riesgo de pérdida de datos en la base no se manifestó. No se detectaron inconsistencias durante el período y el relevamiento de la infraestructura no registra reinicios acumulados en ninguno de los contenedores en servicio.

El riesgo de sobre costos en el consumo de los servicios de inteligencia artificial tampoco se manifestó. Su evaluación exigió recurrir a los paneles de facturación de los dos proveedores, dado que el gasto no queda registrado en ninguna de las fuentes internas del sistema. Sobre la ventana comprendida entre el 4 de junio y el 17 de agosto de 2026 el consumo conjunto totalizó 236,29 dólares estadounidenses, equivalentes a 3,15 dólares diarios y a un costo unitario de 6,1 centavos de dólar por pedido. La planificación no fijó un valor de corte para este rubro, de modo que el contraste no puede establecerse contra un presupuesto previo, pero la magnitud observada resulta holgadamente compatible con la restricción de bajo costo que orienta el trabajo y respalda la decisión de consumir los modelos como servicio en lugar de ejecutarlos sobre infraestructura propia, sobre todo si se considera que ese gasto incluye la redundancia de dos modelos sobre cada imagen y su posterior reconciliación.

Como observación transversal, el dimensionamiento de la infraestructura resultó holgado. El servidor virtual, con cuatro núcleos y 16 gigabytes de memoria, sostuvo la totalidad de los servicios con una carga media inferior a la centésima parte de su capacidad de cómputo, un consumo de memoria de 3,6 gigabytes y

una ocupación de disco del 11 por ciento, tras 227 días de servicio ininterrumpido. La base relacional del sistema ocupa alrededor de 12 megabytes luego de 4934 pedidos y 37931 ítems, mientras que el registro de ejecuciones de la plataforma de orquestación supera los dos gigabytes y medio. Esa desproporción, de más de dos órdenes de magnitud, explica por sí sola la necesidad de la purga automática que restringió la ventana de análisis de la orquestación a catorce días.

5.1.4. Técnicas empleadas

Tres técnicas resultaron decisivas para el desarrollo.

La primera fue la construcción de un servidor de impresión simulado, que reproduce la interfaz del servidor real y registra el ticket en lugar de imprimirlo. Permitted desarrollar y depurar la totalidad de la cadena sin disponer del hardware, que se adquirió cuando el resto del sistema ya se encontraba en operación.

La segunda fue el despliegue escalonado descrito más arriba, que separó la puesta en producción de la interpretación de la puesta en producción de la actuación física.

La tercera fue el lazo de realimentación del catálogo. El panel destaca los ítems que no pudieron asociarse, y el personal del comercio los empleó para ampliar el catálogo de forma progresiva. El caso del huevo resulta ilustrativo: acumuló 55 ocurrencias no asociadas entre el 10 de junio y el 12 de julio, fecha en que el producto se dio de alta, y a partir de entonces no volvió a registrar ningún fallo. Esa técnica no estaba prevista en la planificación y emergió del uso, pero constituyó la mitigación efectiva del riesgo de calidad de la interpretación.

En sentido inverso, dos decisiones no rindieron lo esperado. La ausencia de pruebas automatizadas obligó a diferir toda verificación hasta la operación real, lo que resultó viable en este proyecto por su escala pero no constituye una práctica extrapolable. Y la redundancia de dos modelos de proveedores distintos sobre cada imagen, con un tercer modelo que reconcilia sus lecturas, agrega costo y latencia sin que el trabajo haya podido medir su aporte, dado que el sistema no conserva las lecturas individuales previas a la reconciliación.

5.2. Próximos pasos

Las líneas de continuación se ordenan según su impacto sobre la operación.

La primera es la implementación de una cola de impresiones pendientes con reintento automático al restablecerse el vínculo con el nodo de borde. Es la mejora de mayor impacto sobre la confiabilidad percibida, ya que habría evitado la totalidad de los 15 pedidos que quedaron sin comprobante, y su alcance es superior al del mecanismo de supervisión previsto en la planificación por resolver el problema con independencia de su causa.

La segunda es la extensión del modelo de datos para incorporar el instante de recepción del mensaje, su formato de origen y una referencia al mensaje original. Esa modificación cerraría la discontinuidad de la cadena de trazabilidad y convertiría en permanentes dos mediciones que este trabajo debió reconstruir por inferencia: la latencia extremo a extremo y el desempeño desagregado por formato de entrada.

La tercera es la ampliación del catálogo con las variedades comerciales y los códigos de calibre de los proveedores, junto con una vista del panel que ordene por frecuencia los ítems no asociados. Ambas medidas atacan el 79,48 por ciento del error residual que responde a limitaciones de cobertura, y transformarían en sistemático el lazo de realimentación que hoy opera de manera reactiva.

La cuarta es la revisión del intervalo de espera por inactividad. La medición demostró que el tiempo de interpretación se ubica en el orden de las unidades de segundo, muy por debajo de los sesenta que dura cada ciclo de espera, de modo que su reducción disminuiría la latencia percibida en los pedidos enviados en un único mensaje. Una caracterización previa de la distribución del tiempo entre mensajes sucesivos de un mismo cliente permitiría fijar ese valor con fundamento empírico.

La quinta es la incorporación de pruebas automatizadas sobre los módulos de interpretación e impresión, junto con el registro del operador que dispare cada impresión desde el panel. La primera cancela la deuda técnica señalada; la segunda separaría de forma explícita las dos poblaciones de impresiones que este trabajo debió distinguir por inferencia.

Por último, la evidencia reunida sugiere una línea de trabajo que excede el alcance original. El sistema resuelve algo más del doble de conversaciones que de pedidos, ya que interpreta consultas, confirmaciones y saludos que no derivan en un encargo. Ese volumen, hoy descartado, constituye información sobre la demanda y sobre la interacción con los clientes que el sistema podría aprovechar.

Apéndice A

Capturas del sistema en operación

En este anexo se incluyen las imágenes reales del sistema en funcionamiento: el ticket generado y las vistas del panel web de control.

A.1. Ticket impreso

PEDIDO
Fecha y hora:
30/06/2026 01:43:18
Cliente: Pedro Sanchez
Tel: 5492323999999

- Cebolla: 1 kg

- Batata: 1 kg

- Cebolla: 1 kg

- Brócoli: 1 u.
\$3.000/u. \$3.000

- Batata: 1 kg

- Morrón rojo: 2 u.

- Ají picante: 1 kg
\$14.554/kg \$14.554

- Tomate perita: 1 kg
\$25.000/kg \$25.000

- Morrón rojo: 1 u.

- Tomate perita: 1.5 kg
\$25.000/kg \$37.500

FUERA DE CATALOGO:

- Zapallo paraguayo: 1
a.

TOTAL: \$80.054

ACLARACIONES:

FIGURA A.1. Ticket real generado por el sistema e impreso en el comercio.

A.2. Panel web de control




FIGURA A.2. Tablero principal del panel de control.

Pedidos

Desde 03/05/2026

Hora 00:19

Hasta 04/09/2026

Hora 00:19

Filtrar

Resetear

Todos

Recibidos

En preparación

Listos

Entregados

No vistos

Error impresión

☐	Hora ↑	Cliente	Productos	Total	Estado	Visto
☐	04/08 00:29	Pedro Sanchez	Tomate redondo x1, Zapallito x2...	\$ 25.000	Recibido	
☐	04/08 00:28	Juan Perez	Brócoli x1, Cebolla x1...	\$ 28.000	Recibido	
☐	02/08 16:49	Juan Perez	Acelga x2	—	Recibido	
☐	30/06 16:37	Juan Perez	Acelga x2	\$ 28.000	Recibido	
☐	29/06 22:43	Pedro Sanchez	Cebolla x1, Batata x1...	\$ 80.054	Recibido	
☐	29/06 21:34	Pedro Sanchez	Tomate perita x1, Cebolla x1...	\$ 53.000	Recibido	
☐	25/06 23:13	Juan Perez	Acelga x1	\$ 2.000	Recibido	
☐	04/08 16:16	Juan Perez	Brócoli x1, Cebolla x1...	\$ 28.000	Recibido	

FIGURA A.3. Listado de pedidos con sus filtros de búsqueda.

Pedido #43 Visto

Fecha: 29/06/2026 Hora: 22:43 Estado: Recibido

Cliente: Pedro Sanchez – 5492323999999

Productos + Agregar

Cebolla 1 kg	-		
Brócoli 1 u.	\$ 3.000	→ \$ 3.000	
Morrón rojo 2 unidad	-		
Zapallo paraguayo 1 atado	sin catálogo		
Ají picante 1 kg	\$ 14.554	→ \$ 14.554	
Morrón rojo 1 u.	-		
Tomate perita 1,5 kg	\$ 25.000	→ \$ 37.500	

Subtotal \$ 55.054

+ Descuento | Efectivo -10%

Total \$ 55.054

Aclaraciones

Ej: pedir que esté bien maduro

0/200

[Historial de impresiones \(2\)](#) [Vista previa](#)

No se encontró ninguna conversación en Chatwoot para este contacto

[Duplicar](#) [Imprimir](#) [Confirmar](#) [Cerrar](#) [Guardar](#)

FIGURA A.4. Detalle de un pedido, con edición de ítems y acceso al mensaje original.

Productos

Buscar producto Categoría: Todas ☐ Mostrar inactivos [Exportar precios](#) [Importar precios](#)

Nombre	Categoría	Unidad	Precios	Activo
Aceite	Varios	unidad	\$9.500/unidad	☒
Acelga	Hojas	cajon	\$1.800/atado \$15.000/cajon	☒
Ají Picante	Verduras	cajon	\$-/cajon \$10.000/kg	☒
Ají Vinagre	Verduras	cajon	\$-/cajon \$25.000/cajon \$4.000/kg	☒
Ajo	Varios	riestra	\$1.500/unidad \$50.000/riestra	☒

FIGURA A.5. Administración del catálogo de productos.




FIGURA A.6. Administración de las listas de precios de un cliente.




FIGURA A.7. Vista de métricas de operación del comercio.

Bibliografía

- [1] Shopify. *Shopify POS: sistema de punto de venta*. Shopify. URL: <https://www.shopify.com/pos> (visitado 06-07-2026).
- [2] Tiendanube. *¿Qué es Punto de Venta de Tiendanube?* Tiendanube. URL: https://ayuda.tiendanube.com/es_AR/pdv/que-es-punto-de-venta-de-tiendanube (visitado 06-07-2026).
- [3] n8n. *n8n: Workflow Automation*. n8n. URL: <https://n8n.io> (visitado 06-07-2026).
- [4] Zapier. *Zapier: Automation for Business*. Zapier. URL: <https://zapier.com> (visitado 06-07-2026).
- [5] Weisong Shi et al. «Edge Computing: Vision and Challenges». En: *IEEE Internet of Things Journal* 3.5 (oct. de 2016), págs. 637-646. DOI: [10.1109/JIOT.2016.2579198](https://doi.org/10.1109/JIOT.2016.2579198).
- [6] Mahadev Satyanarayanan. «The Emergence of Edge Computing». En: *Computer* 50.1 (ene. de 2017), págs. 30-39.
- [7] Liang Tong, Yong Li y Wei Gao. «A Hierarchical Edge Cloud Architecture for Mobile Computing». En: *IEEE INFOCOM 2016 – The 35th Annual IEEE International Conference on Computer Communications*. San Francisco, CA, USA: IEEE, abr. de 2016, págs. 1-9.
- [8] Microsoft. *Windows Server*. Microsoft. URL: <https://www.microsoft.com/en-us/windows-server> (visitado 20-07-2026).
- [9] Raspberry Pi Ltd. *Raspberry Pi*. Raspberry Pi Ltd. URL: <https://www.raspberrypi.com> (visitado 20-07-2026).
- [10] Compañía Hasar. *Impresora térmica P-HAS-181*. Grupo Hasar. URL: <https://compania.grupohasar.com/producto/p-has-181/> (visitado 13-07-2026).
- [11] Seiko Epson Corporation. *ESC/POS Command Reference for TM Printers*. Epson. URL: https://download4.epson.biz/sec_pubs/pos/reference_en/escpos/index.html (visitado 20-07-2026).
- [12] Roy T. Fielding, Mark Nottingham y Julian Reschke. *HTTP Semantics*. Request for Comments 9110. Internet Engineering Task Force, jun. de 2022. DOI: [10.17487/RFC9110](https://doi.org/10.17487/RFC9110). URL: <https://www.rfc-editor.org/info/rfc9110> (visitado 20-07-2026).
- [13] Roy Thomas Fielding. «Architectural Styles and the Design of Network-based Software Architectures». Tesis doct. University of California, Irvine, 2000.
- [14] Meta. *WhatsApp*. Meta Platforms. URL: <https://www.whatsapp.com> (visitado 04-08-2026).
- [15] Evolution API. *Evolution API: Open-source WhatsApp Integration API*. Evolution API. URL: <https://github.com/EvolutionAPI/evolution-api> (visitado 13-07-2026).
- [16] WhiskeySockets. *Baileys: WhatsApp Web API*. WhiskeySockets. URL: <https://github.com/WhiskeySockets/Baileys> (visitado 03-08-2026).
- [17] Meta. *WhatsApp Business Platform*. Meta Platforms. URL: <https://developers.facebook.com/docs/whatsapp> (visitado 06-07-2026).

- [18] Chatwoot. *Chatwoot: Open-source customer engagement platform*. Chatwoot. URL: <https://www.chatwoot.com> (visitado 04-08-2026).
- [19] Cloudflare. *Cloudflare Tunnel*. Cloudflare. URL: <https://www.cloudflare.com/products/tunnel/> (visitado 06-07-2026).
- [20] Hostinger. *VPS Hosting*. Hostinger. URL: <https://www.hostinger.com/vps-hosting> (visitado 13-07-2026).
- [21] Docker. *Docker: Accelerated Container Application Development*. Docker, Inc. URL: <https://www.docker.com> (visitado 06-07-2026).
- [22] OpenAI. *OpenAI Platform*. OpenAI. URL: <https://platform.openai.com> (visitado 06-07-2026).
- [23] Anthropic. *Claude*. Anthropic. URL: <https://www.anthropic.com/claude> (visitado 13-07-2026).
- [24] OpenAI. *Whisper: Robust Speech Recognition*. OpenAI. URL: <https://github.com/openai/whisper> (visitado 06-07-2026).
- [25] The PostgreSQL Global Development Group. *PostgreSQL: The World's Most Advanced Open Source Relational Database*. The PostgreSQL Global Development Group. URL: <https://www.postgresql.org> (visitado 06-07-2026).
- [26] Redis. *Redis: The Real-time Data Platform*. Redis. URL: <https://redis.io> (visitado 06-07-2026).
- [27] Pallets. *Flask: Web Development, One Drop at a Time*. Pallets. URL: <https://flask.palletsprojects.com> (visitado 06-07-2026).
- [28] Python Software Foundation. *Python*. Python Software Foundation. URL: <https://www.python.org> (visitado 04-08-2026).
- [29] Google. *Angular*. Google. URL: <https://angular.dev> (visitado 20-07-2026).
- [30] Chart.js. *Chart.js: Simple yet flexible JavaScript charting library*. Chart.js. URL: <https://www.chartjs.org> (visitado 20-07-2026).
- [31] OpenJS Foundation. *Node.js*. OpenJS Foundation. URL: <https://nodejs.org> (visitado 04-08-2026).
- [32] OpenJS Foundation. *Express: Fast, unopinionated, minimalist web framework for Node.js*. OpenJS Foundation. URL: <https://expressjs.com> (visitado 04-08-2026).
- [33] Microsoft. *TypeScript: JavaScript With Syntax For Types*. Microsoft. URL: <https://www.typescriptlang.org> (visitado 04-08-2026).
- [34] Prisma. *Prisma: Next-generation Node.js and TypeScript ORM*. Prisma. URL: <https://www.prisma.io> (visitado 04-08-2026).